

学 号 2021201223

密 级 _____

哈尔滨工程大学本科生毕业论文

工业设备故障检测系统设计与实现

院（系）名 称：计算机科学与技术学院

专 业 名 称：软件工程

学 生 姓 名：钱柯

指 导 教 师：吕继光

哈尔滨工程大学

2025 年 5 月

工业设备故障检测系统设计与实现

钱柯

哈尔滨工程大学

学 号 2021201223

密 级

工业设备故障检测系统设计与实现

Design and Implementation of Industrial Equipment Fault Detection System

学 生 姓 名: 钱柯

所 在 学 院: 计算机科学与技术学院

所 在 专 业: 软件工程

指 导 教 师: 吕继光

职 称: 副教授

所 在 单 位: 哈尔滨工程大学

论文提交日期: 2025 年 5 月

论文答辩日期: 2025 年 6 月

学位授予单位: 哈尔滨工程大学

哈尔滨工程大学

学位论文原创性声明

本人郑重声明：本论文的所有工作，是在导师的指导下，由作者本人独立完成的。有关观点、方法、数据和文献的引用已在文中指出，并与参考文献相对应。除文中已注明引用的内容外，本论文不包含任何其他个人或集体已经公开发表的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

作者(签字)： 戚柯

日期：2025 年 6 月 12 日

哈尔滨工程大学

学位论文授权使用声明

本人完全了解学校保护知识产权的有关规定，即在校攻读学位期间论文工作的知识产权属于哈尔滨工程大学。哈尔滨工程大学有权保留并向国家有关部门或机构送交论文的复印件。本人允许哈尔滨工程大学将论文的部分或全部内容编入有关数据库进行检索，可采用影印、缩印或扫描等复制手段保存和汇编本学位论文，可以公布论文的全部内容。同时本人保证毕业后结合学位论文研究课题再撰写的论文一律注明作者第一署名单位为哈尔滨工程大学。涉密学位论文待解密后适用本声明。

本论文（☒在授予学位后即可 ☐在授予学位 12 个月后 ☐解密后）由哈尔滨工程大学送交有关部门进行保存、汇编等。

作者(签字)： 戚柯

导师(签字)： 吕建光

日期：2025 年 6 月 12 日

2025 年 6 月 12 日

摘 要

随着人工智能的发展的浪潮席卷全球，因其具备高度智能化与自主学习能力，强大的感知、理解与推理能力驱动各行业生态体系深度变革。深度学习与工业故障检测系统的融合是重要的研究方向与发展趋势，值得我们下功夫去研究，特别是在识别分类、系统设计、性能预测、故障检测等方面。基于深度学习与大数据分析可以从海量数据中发现工业设备故障数据的规律，从而精确识别潜在故障。

本文旨在设计完成一个工业设备故障检测的可视化系统，基于已有的数据集，完成了对数据清洗，数据特征提取等数据预处理过程。设计并实现了基于文本信息模态的故障检测模型，基于音频信息模态的故障检测模型和基于音频模态的机械部位判断模型。本文先通过基于音频信息判断机械部位模型来判断音频和文本信息是属于哪个机械部位的，再通过对基于文本信息模态故障检测模型的结果和基于音频信息模态故障检测模型的结果做余弦相似度计算来判断对应机械部位是否故障。最后本文完成了工业故障检测系统的可视化和对应的系统测试，来确保用户使用体验。

关键词：前馈神经网络模型；循环神经网络模型；故障检测；多模态

ABSTRACT

With the development of artificial intelligence sweeping the world, it has driven deep changes in the ecosystem of various industries due to its high intelligence and self-learning capabilities, as well as its strong perception, understanding and reasoning capabilities. The integration of deep learning and industrial fault detection system is an important research direction and development trend, which is worthy of our efforts, especially in identification and classification, system design, performance prediction, fault detection, etc. Based on deep learning and big data analysis, the rules of industrial equipment failure data can be found from massive data, so as to accurately identify potential faults.

The purpose of this thesis design a visualization system for industrial equipment fault detection, and complete the data preprocessing process such as data cleaning and data feature extraction based on the existing data set. A fault detection model based on text information modality, a fault detection model based on audio information modality, and a mechanical part judgment model based on audio modality were designed and implemented. In this paper, we first determine which mechanical part the audio and text information belong to by judging the mechanical part model based on audio information, and then calculate the cosine recognition degree based on the results of the textual information-based modal fault detection and the results of the audio-information-based modal fault detection model to determine whether the corresponding mechanical part is faulty. Finally, this paper completes the visualization of the industrial fault detection system and the corresponding system test to ensure the user experience.

Keywords: Feedforward neural network model; Recurrent neural network model; Fault detection; Multimodal

目 录

第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.3 主要工作内容	3
1.4 论文结构	3
第 2 章 核心技术概要	4
2.1 前馈神经网络模型	4
2.2 循环神经网络模型	5
2.3 MFCCT 处理	7
2.4 PYTORCH 框架	7
2.5 DJANGO 框架	8
2.6 本章小结	8
第 3 章 神经网络模型的设计与实现	9
3.1 基于文本模态的故障检测模型的设计与实现	9
3.1.1 数据的搜集与清洗	9
3.1.2 前馈神经网络模型的训练	10
3.1.3 前馈神经网络模型训练结果	11
3.2 基于音频模态的机械部位检测模型的设计与实现	14
3.2.1 数据搜集	14
3.2.2 数据清洗与 MFCCT 处理	14
3.2.3 循环神经网络模型的训练	16
3.2.4 循环神经网络模型训练结果	17
3.3 基于音频模态的故障检测模型的设计与实现	19
3.3.1 数据清洗	19
3.3.2 数据清洗与 MFCCT 处理	20
3.3.3 循环神经网络模型	21
3.3.4 循环神经网络模型训练结果	21
3.4 本章小结	26

第 4 章 工业设备故障检测系统的设计与实现.....	27
4.1 项目需求分析	27
4.2 系统主要功能的设计与实现	28
4.2.1 多模态故障检测的实现逻辑	28
4.2.2 故障检测功能输入页的设计与实现	29
4.2.3 故障检测结果页的设计与实现	32
4.3 系统次要功能的设计与实现	33
4.3.1 用户登入功能的设计与实现	33
4.3.2 系统主页的设计与实现	35
4.3.3 权限用户添加功能的设计与实现	36
4.4.4 模型详解页的设计与实现	38
4.4 系统测试	42
4.4.1 系统测试的概念和目的	42
4.4.2 系统功能测试	42
4.4.3 系统测试结果	44
4.5 本章小结	45
结 论	46
参考文献	48
攻读学士学位期间取得的学术成果	51
致 谢	52

第 1 章 绪论

1.1 研究背景与意义

在工业 4.0 与智能制造转型的浪潮下，聚焦国家工业需求，工业设备故障检测已成为保障生产安全、提升效率的核心环节^[1]。传统检测方法依赖人工巡检或固定阈值监测，存在效率低、漏检率高、实时性差等瓶颈^[2]。例如，人工目视检测难以捕捉微小裂纹或早期故障征兆^[3]，而无损检测技术（如超声、射线检测）虽能提升精度，但设备成本高、操作复杂，且需专业人员解读结果^[4]。此外，传统方法缺乏对多源异构数据的融合分析能力，难以应对复杂工业场景中设备状态的非线性变化^[5]。同时随着工业互联网的普及，设备运行数据呈指数级增长，传统架构已无法满足高效处理与实时响应的需求^[6]。因此大量技术人员将目光投入到深度学习方面，希望通过大量数据的学习来训练出合格的模型来判断机械部位是否故障^[7]。

目前深度学习方面一般都是单模态（如温度和压力这种单独的文本信息或音频或图像）模型来判断，但在复杂工业场景中，设备故障往往呈现多物理场耦合特征，依赖单一模态数据难以准确捕捉设备的复杂行为和潜在故障^[8]。例如，轴承早期故障可能仅在特定频段振动信号中显现，而温度数据可辅助验证故障发展阶段。在大量技术人员的推动下，工业设备故障检测正经历从单模态分析向多模态融合的技术跨越。不同于单模态模型只能检测已知的故障，多模态模型是基于多个不同模态信息来综合判断，这意味着其能对场景信息进行全面利用，让其能对未知或即将发生的故障进行有效预测和判断。

同时本系统还结合了知识图谱，知识图谱的应用简化了系统操作人员的操作。如，在本系统中，操作人员不需要分清音频和文本信息具体是哪个机械部位产生的，只需要将音频和文本信息输入，本工业机械故障检测系统将根据知识图谱自动推理是机械哪个部位出现故障，减少了工人对本系统的学习成本。

总而言之，如今，人工智能（Artificial Intelligence, AI）浪潮席卷全球，其具备高度智能化与自主学习能力，强大的感知、理解与推理能力驱动各行业生态体系深度变革^[9]。所以，AI 与工业故障检测系统的融合是重要的研究方向与发展趋势，值得我们下功夫去研究，特别是在识别分类、系统设计、性能预测、故障检测等方面^[10]。AI 技术加速了工业设备故障检测与诊断效率，基于深度学习与大数据分析可以从海量数据中发现工业设备故障数据的规律，从而精确识别潜在故障^[11]。

1.2 国内外研究现状

近年来，中国在基于深度学习的工业故障检测领域取得了显著进展，研究重点聚焦于模型创新与工业场景深度融合。卷积神经网络（CNN）^[12-14]在旋转机械故障识别^[15]中应用广泛，例如，某团队开发的八层 CNN 模型^[16]通过振动信号频谱分析^[17]，成功识别轴承内圈裂纹等七种故障类型，诊断准确率较传统方法提升 23%。此外，三维卷积网络在齿轮箱多传感器数据融合中展现优势，但训练耗时问题仍需优化。针对时序数据处理，循环神经网络（RNN）及其变体（如双向门控循环单元）表现突出，某研究团队提出的模型在燃气轮机异常检测中实现提前 30 分钟预警，误报率降至 0.7%。长短期记忆网络（LSTM）在风电场叶片故障预测^[18]中准确率达 91%。为解决小样本问题，生成对抗网络（GAN）^[19]被用于数据增强，某团队仅需 50 组真实样本即可生成高质量仿真数据，汽车制造企业通过该技术扩充变速箱故障数据集后，模型泛化能力提升 18%。跨领域迁移学习也成为研究热点，某实验室提出的领域自适应框架成功将数控机床诊断模型迁移^[20]至工业机器人领域，适应过程仅需目标领域 2% 的数据量。此外，模型轻量化技术取得突破，某团队设计的深度可分离卷积网络在保持 98% 诊断精度的同时，模型体积压缩至原尺寸的 1/5，满足工业实时性需求。

国外研究现状：国际上，基于深度学习的工业故障检测研究更注重理论应用与多模态融合。Niu 等提出集成主成分分析和深度置信网络的方法，避免人工特征提取^[21]；Dixit 等利用 GAN 解决故障样本不足问题，但未充分考虑强噪声环境影响^[22]；Liu 等提出增量补偿算法动态深度学习模型，针对类别不平衡样本进行增量学习^[23]。在多模态数据融合方面，Alex 等将 CNN 与 RNN（LSTM）结合，实现滚动轴承的故障诊断^[24]。此外，国外研究充分利用工业互联网产生的海量数据，例如，风电机组状态监测系统（SCADA 和 CMS）的数据被用于深度学习模型训练，实现早期故障预警和定位^[25]。针对小样本和跨场景诊断问题，改进生成对抗网络和迁移学习技术被广泛应用^[26-27]。

研究热点与趋势：当前，多模态数据融合成为提升诊断精度的关键路径，结合振动、声音、红外、电流等多源信号构建全面设备状态表征^[28]。迁移学习与小样本学习技术受到关注，以降低对大规模标注数据的依赖^[29]。模型轻量化与边缘部署研究推动深度学习模型在工业现场的实时应用。可解释性与可视化技术（如注意力机制分析、因果推理模块）提高模型可信度。此外，数字孪生与在线增量学习框架成为未来方向，支持设备虚拟模型与实体同步更新及模型持续适应设备老化特征^[30]。国内外研究均表明，深度学习技术正推动工业故障检测向智能化、实时化、泛化能力强的方向发展。

1.3 主要工作内容

本文在对当前国内外工业故障检测系统相关知识的学习与分析的基础上，选择python作为开发语言，pytorch框架来训练项目中进行判断的模型，使用余弦相似度来对不同模态模型结果进行计算得到结果，最后用django框架来实现可视化。本系统能实现对输入文本信息模态和音频信息模态进行推理判断是属于哪个机械部位的同时判断该机械部位是否故障。

本文的主要工作内容包括：

- (1) 文本信息（如温度，压力等）模态模型判断机械部位是否故障的训练。
- (2) 音频信息模态模型判断机械部位是否故障的训练。
- (3) 音频信息模态模型判断机械部位的训练。
- (4) 多模态信息故障检测的实现。
- (5) 项目的可视化与项目的系统测试。

1.4 论文结构

本文共分为4章，各章主要内容如下：

第1章：绪论，首先分析了工业设备故障检测系统的研究背景与意义，然后对国内外的工业故障检测系统的相关技术研究现状进行了总结与分析，最后给出了本文的主要工作内容与论文结构。

第2章：对实现项目的核心技术进行简述。

第3章：进行项目所需的神经网络模型的训练，完成文本信息模型判断机械部位是否故障的训练，分析前馈神经网络模型对任务性能是否能满足。完成音频信息模态模型判断机械部位是否故障的训练与音频信息模态模型判断机械部位的训练，分析循环神经网络模型对任务性能是否能满足。

第4章：项目的需求分析与实现，根据需求分析完成项目功能的可视化和项目的系统测试。

最后对全文进行适当总结，指出系统中尚未完成或不足的地方，并明确未来的工作计划和展望。

第 2 章 核心技术概要

2.1 前馈神经网络模型

前馈神经网络（Feedforward Neural Network，简称 FNN）是最基础、最经典的人工神经网络结构之一，是理解深度学习和其他神经网络模型的起点。在这种网络结构中，信息从输入层开始，依次传递到一个或多个隐藏层，最后到达输出层，整个过程是单向的，信息在网络中不产生循环或反馈，因此被称为“前馈”结构。这种结构简单、清晰，便于理解和实现。前馈神经网络由多个神经元组成，每一层的神经元与下一层的所有神经元之间均为全连接，而同一层的神经元之间则没有连接。每个神经元通过加权求和和激活函数对输入进行非线性变换，从而增强模型对复杂数据的表达能力。通过多个隐藏层的组合，前馈神经网络可以逼近任意复杂的非线性函数，用于实现从输入到输出之间的高维映射。前馈神经网络不仅是独立使用的强大模型，还是许多复杂神经网络结构的基础。例如，卷积神经网络（Convolutional Neural Network，CNN）就是在前馈神经网络的基础上发展而来，专门用于处理图像、语音等具有空间或时间结构的数据。CNN 保留了前馈结构中信息单向传递的基本计算框架，同时引入了局部感受野、共享权重和池化等机制，使得它在处理高维结构化数据时具有更高的效率和表达能力。总之，前馈神经网络作为深度学习中最基本的模型，具有重要的理论和实践意义。它不仅能用于回归、分类等基本任务，也为卷积神经网络、循环神经网络等更复杂结构的设计提供了核心思想。通过对其结构和训练机制的深入理解，有助于更好地掌握神经网络的工作原理及其在各类任务中的应用。

前馈神经网络有以下 4 点优点：（1）前馈神经网络模型结构简单，容易实现，方便新手学习和理解神经网络模型。同过学习前馈神经网络模型，能为以后对其他更复杂的神经网络模型的学习打下坚实的基础。（2）前馈神经网络模型具有非常强大的非线性拟合能力。（3）前馈神经网络经过许多年的发展，其理论支持与实践十分丰富，新手能方便的学习，使用和调整前馈神经网络模型来实现自己项目的目标。即前馈神经网络模型能根据项目来因地制宜的调整改造。（4）前馈神经网络模型因其结构简单无循环连接，其计算效率十分高效，方便迭代模型。

前馈神经网络模型的数据训练流程如下图 2.1 前馈神经网络结构图所示：如图所示，每个圆圈都代表一个神经元，前馈神经网络模型数据的流向是从输入层开始流向隐藏层，再从隐藏层流向输出层。隐藏层的个数是自定义的，可以有一个或多个，隐藏层越多对输入数据的特征理解的就越清晰，但相应的模型复杂度就越高训练时间就越长。训练前馈神经网络模型输入数据的特征数代表着输入层神经元的个数，隐藏层用

于捕获数据的非线性特征。每个隐藏层由多个神经元组成，每个神经元通过激活函数增加非线性能力。输出层输出网络的预测结果。层与层间的连接由每个神经元的输入通过权重进行加权求和，并加上偏置值，然后通过激活函数传递。




图 2.1 前馈神经网络结构图

2.2 循环神经网络模型

循环神经网络（RNN）模型是专门用于处理序列数据的神经网络模型，是理解时序建模和动态系统的关键，常作为自然语言处理、语音识别等复杂任务的基石。许多现代神经网络架构（如 LSTM、GRU、Transformer）均在其基础上发展而来。RNN 通过引入循环连接，使得信息能够在时间步之间传递，从而捕捉序列中的长期依赖关系。它由输入层、隐藏层（包含循环状态）和输出层组成，数据在网络中沿时间轴动态流动，隐藏状态在时间步间迭代更新，形成循环反馈机制。这种结构使得 RNN 能够处理变长输入序列（如文本、时间序列），并通过隐藏状态保留历史上下文信息。隐藏状态 h_t 不仅依赖当前输入 x_t ，还依赖上一时刻的隐藏状态 h_{t-1} ，即 $h_t = f(W_{xh}x_t + W_{hh}h_{t-1} + b_h)$ ，其中 f 为激活函数。

循环神经网络模型有以下 3 点优点：（1）动态时序建模能力：RNN 天然适合处理序列数据，能够捕捉时间步间的依赖关系，是文本生成、时间序列预测等任务的基础。

（2）参数共享与灵活性：同一组权重在序列中重复使用，减少参数数量的同时适应变长输入，如第三章使用时，定义的循环神经网络模型并不在乎音频输入的长度，只需用对其

做 MFCCT 处理时都定义生成 40 维梅尔滤波器组，输出的张量形状为 $(T, 120)$ 即可，不用在乎 T 的长度。模型结构可根据任务需求调整（如双向 RNN）。（3）理论与应用成熟：经过多年发展，RNN 及其变体在学术界和工业界有广泛研究与应用，新手可通过学习 RNN 快速掌握时序建模的核心思想。

循环神经网络模型的数据训练流程如下图 2.3 循环神经网络结构图：




图 2.2 循环神经网络结构单元图




图 2.3 循环神经网络结构图

在图 2.3 循环神经网络结构图中，圆圈 X_t 表示当前时间步的输入，圆圈 X_{t-1} 表示前一个时间步的输入，以此类推。中间的方块为隐藏状态，它在每个时间步存储有关序列的信息。 U 为输入到隐藏状态的权重矩阵，用于将输入 X_t 转换为隐藏状态的一部分。 W 为隐藏状态到隐藏状态的权重矩阵，用于将前一时间步的隐藏状态 h_{t-1} 转换为当前时间步隐藏状态的一部分。 V 为隐藏状态到输出的权重矩阵，用于将隐藏状态 h_t 转换为输出

Y_t 。圆圈 Y 表示在每个时间步的输出，如 Y_t 是当前时间步的输出。

图 2.2 循环神经网络结构单元图可以简单的理解成图 2.1 前馈神经网络结构图的结构样式。圆圈 X 代表图 2.1 中的输入层，矩阵可以理解成图 2.1 中的隐藏层，圆圈 Y 可以理解成图 2.1 中的输出层。

2.3 MFCCT 处理

MFCCT^[31] (Mel-Frequency Cepstral Coefficients with Temporal Processing) 模型是语音信号处理领域的基础模型，专注于从音频中提取时间序列特征，是语音识别、说话人识别等任务的核心组成部分。其处理流程严格遵循人耳听觉特性，通过时频变换与动态特征增强，将原始语音信号转化为高区分度的特征向量。

对音频进行 MFCCT 处理有以下 4 点优势：（1）人耳感知适配性：梅尔滤波器组与对数运算紧密贴合人耳听觉特性，显著提升噪声环境下的鲁棒性。（2）时序特征表达能力：差分运算与帧能量补充静态 MFCC 的时序建模短板，尤其适用于连续语音识别任务。（3）计算高效性：DCT 变换后的低维特征（如 13 维）大幅降低后续模型复杂度，适合实时处理场景。（4）模块化扩展性：可灵活组合预加重参数、滤波器数量、差分阶数等，适配不同任务需求（如低资源设备优化）。

2.4 PYTORCH 框架

PyTorch 是由 Facebook（现 Meta）人工智能研究院（FAIR）主导开发的一款开源 Python 机器学习库，自推出以来便迅速成为深度学习领域的重要工具之一。其最大的亮点之一在于提供了动态计算图机制，这一特性使得用户在构建和修改神经网络模型时能够享受到前所未有的灵活性。与静态计算图不同，动态计算图允许在运行时动态地定义和调整网络结构，这对于需要频繁实验和调试的深度学习研究来说，无疑是一个巨大的福音。开发者可以根据实际需求，在代码中即时添加、删除或修改网络层，而无需预先定义整个计算图，从而极大地提高了开发效率。此外，PyTorch 内置了丰富的神经网络模型组件和模块，覆盖了从基础的全连接层、卷积层到复杂的循环神经网络、注意力机制等，为使用者提供了多样化的选择。这些预定义的模型组件不仅易于集成到新的项目中，而且通过高度优化的实现，能够显著提升模型的训练速度和性能。

PyTorch 还提供了简洁而强大的 API 接口，涵盖了自动求导、优化器、数据加载器等深度学习流程中的关键环节。特别是其自动求导机制，能够自动计算梯度，极大地简化了反向传播算法的实现过程，让开发者能够更专注于模型的设计和优化。更为重要的是，PyTorch 支持 GPU 加速，能够充分利用图形处理器的并行计算能力，大幅加速模型的训练和推理过程。这一特性对于处理大规模数据集和复杂模型尤为重要，能够显著缩

短实验周期，提升研发效率。

凭借这些优势，PyTorch 在学术研究和工业界均得到了广泛应用，成为推动计算机视觉、自然语言处理、强化学习等多个领域模型开发的重要力量。

2.5 DJANGO 框架

Django 是一个基于 Python 语言构建的开源高级 Web 框架，其设计遵循 MTV(Model-Template-View) 设计模式，这一模式将数据模型、用户界面模板和业务逻辑视图分离，使得代码结构更加清晰，便于维护和扩展。Django 提供了丰富的内置功能和工具，例如 ORM（对象关系映射）能够轻松实现数据库操作，而无需编写复杂的 SQL 语句；自动管理后台功能可快速生成数据管理界面，提升开发效率；表单处理工具则简化了用户输入的验证与处理流程。这些功能共同支持开发者快速构建功能完善的 Web 应用。此外，Django 高度重视安全性，内置了多种防护机制，如防止跨站脚本攻击（XSS）和 SQL 注入等。同时，它具备强大的可扩展性，允许开发者通过集成如 pymysql 等第三方库，进一步丰富网站功能，满足多样化的开发需求。

2.6 本章小结

本章对论文使用的核心技术进行了简述。对下文将要设计并实现的两种神经网络模型进行讲述，为理解下文如何训练相关神经网络模型打下了基础，特别是对音频部分将要使用的循环神经网络模型，了解其模型结构对理解下文有巨大帮助。对音频数据要使用的 MFCCT 处理技术和本项目要使用的框架进行讲述。

第3章 神经网络模型的设计与实现

3.1 基于文本模态的故障检测模型的设计与实现

根据文本信息模态来判断机械部位是否故障的神经网络模型的网络结构是前馈神经网络。前馈神经网络模型不仅结构简单，训练快速简单，还在回归预测任务方面表现优秀。回归预测任务是 $(\text{int } a, \text{int } b, \text{int } c, \dots, \text{int } x) \rightarrow (\text{int } y)$ 形式的数据推理任务。与项目本部分功能需实现的数据形式相吻合。

3.1.1 数据的搜集与清洗

此部分需要完成对前馈神经网络模型输入模型数据的搜集与清洗。原始数据集搜集方面是通过在 kaggle 网站下载数据集实现的。其原始数据的格式为表 3.1。其中 faulty 列中 0 表示部位正常，1 表示部位故障。

为了满足前馈神经网络模型训练时的模型输入需求，需要将这些数据按机械部位分类转化成二维张量的形式。由表 3.1 原始数据表中 equipment 列可知表中数据按机械部位可以分为三类，分别为 Turbine 类，Compressor 类和 Pump 类。在数据处理中只需先将表中数据存入形状为 $(n, 6)$ 的二维矩阵中， n 表示表中数据的行数。再按上述机械部位分类储存在三组不同的形状为 $(n, 5)$ 的二维矩阵中， n 为对应机械类型的数据长度，缺少的列为 equipment 列。再将二维矩阵切割成形状为 $(n, 4)$ 的二维矩阵和形状为 $(n, 1)$ 的二维矩阵，faulty 列单独切割成形状为 $(n, 1)$ 的二维矩阵。将上述两矩阵转化成二维张量，来满足前馈神经网络模型的输入要求。其中形状为 $(n, 4)$ 的二维张量做为前馈神经网络模型的输入，形状为 $(n, 1)$ 的二维张量作为前馈神经网络模型输出的目标数来和模型本身的输出做比较，来调整前馈神经网络模型训练中的参数。

表 3.1 原始数据表

temperature	pressure	vibration	humidity	equipment	faulty
58.18018003	25.02927765	0.606516217	45.69490710	Turbine	0
75.74071220	22.95401759	2.338094753	41.86740679	Compressor	0
79.61698526	32.24292130	1.770689686	40.56513821	Pump	0
----	----	----	----	----	----
49.51095945	168.5632	4.809297752	20.26969224	Compressor	1
66.90350286	167.3325	1.548345351	64.80492512	Compressor	0

3.1.2 前馈神经网络模型的训练

前馈神经网络是这些年研究的热点之一，因其具有结构简单，训练相对容易，不需要对应用系统进行建模，无模型依赖性仅需输入输出样本即可学习映射关系，适用于未知系统建模（如工业控制中的黑箱系统）。同时其局部损伤容忍性强，大规模网络中，个别神经元失效对整体性能影响有限。例如，在本工业设备故障检测系统预测中，即使部分文本信息数据（如 temperature）缺失失真，模型仍能保持稳定输出。

前馈神经网络其核心特点是信息仅沿单一方向（输入层→隐藏层→输出层）传递，无环路或反馈连接。其网络结构由输入层，多个隐藏层，输出层构成，不同层可以包含多个节点，层与层之间的节点相互连接，层中的节点不连接，前馈神经网络会记录每对相连节点的权重和偏置。前馈神经网络节点间连接如第二章图 2.1 所示。

在本次实现的工业设备故障检测系统中前馈神经网络的输入层 4 个特征数，分别为 temperature（温度），pressure（压力），vibration（振动），humidity（湿度）。其中输入层到隐藏层是通过输入数据 X （文本向量）通过权重矩阵 $W(1)$ 和偏置向量 $b(1)$ 进行线性变换，其公式如下：

$$z(1) = W(1)X + b(1) \quad (3-1)$$

在本工业设备故障检测系统中第一层隐藏层的神经元我设为 16 个，因此 X 向量是 $4 * 1$ 的矩阵， $W(1)$ 为 $16 * 4$ 的矩阵， $B(1)$ 为 $16 * 1$ 的矩阵。其代表意义是 $z(1)$ 是输入信号的加权和，权重 $W(1)$ 反映特征重要性，偏置 $b(1)$ 控制激活阈值。由于上述计算是线性的，而工业设备故障的发生和其温度，压力等参数肯定不是线性关系，所以上述计算不能很好的满足要求。因此我们需要引入激活函数，在工业设备故障检测系统本部分功能实现中我采用的激活函数是：

$$\text{ReLU: } g(z) = \max(0, z) \quad (3-2)$$

其计算高效，能有效缓解梯度消失。通过上述两公式的计算输出 $a(1) = g(z(1))$ ，可以将输入层非线性的转换成第一个隐藏层。

在本此工业故障检测系统的设计与实现中，我选择了两层隐藏层的结构。这是因为隐藏层只有一层的话不能对工业机械设备故障进行很好的预测。在只有一层隐藏层的模型中对工业机械设备故障的检测的准确率和每轮训练的损失值（衡量模型预测结果与真实标签之间差异的核心指标，本系统采用二元交叉熵损失）都不是很理想，其损失值在下降到 0.27 左右就已经无法再继续下降，其数值过大表示模型复杂度不足。因此采用两层隐藏层的结构。第一层隐藏层到第二层隐藏层为递归线性组合第 1 层的输入为前一层的激活输出 $a(1)$ ，计算公式为：

$$z(2) = W(2)a(1) + b(2) \quad (3-3)$$

在本工业设备故障检测系统中第二层隐藏层的神经元我设为 8 个，因此 $W(2)$ 为 $8 * 16$ 的矩阵， $a(1)$ 是上一层的结为 $16 * 1$ 的矩阵， $b(2)$ 为 $8 * 1$ 的矩阵。同样此层也需要引入激活函数，来满足数据由第一层隐藏层到第二层隐藏层的非线性转变。其激活函数也为 ReLU 函数。最后第一层隐藏层到第二层隐藏层的输出结果为 $a(2) = \text{ReLU}(z(2))$ 。

在本前馈神经网络模型训练中，第二层隐藏层到输出层的计算公式为：

$$z(L) = W(L)a(1) + b(L) \quad (3-4)$$

其参数设置 $W(L)$ 为 $1 * 8$ 的矩阵，这是因为我输出层的神经元只设置了一个，输出 0 表示机械部位正常，1 表示机械部位不正常。同样有隐藏层到输出层也需要满足非线性的变化，因此引入激活函数 Sigmoid 函数：

$$\sigma(x) = \frac{1}{1+e^{-x}} \quad (3-5)$$

此激活函数将输入值映射到(0,1)区间，输出可解释为概率，广泛应用于二分类任务和需要非线性建模的场景。可以满足本前馈神经网络模型要实现的判断机械是否故障功能的需求。

3.1.3 前馈神经网络模型训练结果

在完成训练前馈神经网络模型所需要的数据的搜集与清洗工作后，再详细的讲解了前馈神经网络模型的各层数据是如何流转的。完整前向传播为：

$$z(1) = W(1)X + b(1); a(1) = \text{ReLU}(z(1)) \quad (3-6)$$

$$z(2) = W(2)a(1) + b(2); a(2) = \text{ReLU}(z(2)) \quad (3-7)$$

$$z(L) = W(L)a(1) + b(L); y = \text{Sigmoid}(z(L)) \quad (3-8)$$

通过逐层线性组合与非线性激活，实现了从原始输入到高层抽象特征的映射。其计算公式遵循 $z = WX + b \rightarrow a = g(z)$ 的递归模式，输出层为 0 对应正常，1 对应故障的映射方式。

在对工业机械设备中涡轮部分进行故障检测的研究中，采用了前馈神经网络模型对其进行建模与训练。为了评估模型在实际应用中的准确性，选取了部分数据进行验证测试。具体而言，通过 2565 条数据样本输入模型进行预测，每条数据样本由四个关键传感器参数组成，即温度(temperature)、压力(pressure)、振动(vibration)和湿度(humidity)，这些数据以一维张量的形式输入模型。模型输出的预测结果与每条样本的实际故障标签(faulty)进行对比分析，从而计算出涡轮部位前馈神经网络模型的故障检测准确率。最终得出，该模型在当前实验条件下的准确率为 97.03%，表明其在识别涡轮故障方面具有较高的可靠性和实用性。此外，涡轮部分前馈神经网络模型随每轮模型训练时的损失值如下图所示图 3.1 涡轮部分模型损失值随训练轮次变化图所示：




图 3.1 涡轮部分模型损失值随训练轮次变化图

在图 3.1 中可以观察到，前馈神经网络模型训练时模型损失值随着训练轮次的增加而变小，最后在趋于 0.1 时逐渐不变。神经网络模型的损失值是模型预测输出与实际目标值之间差异的度量。在训练过程中，模型通过调整权重和偏置来最小化这个损失值。由此可见，模型在训练轮次到 51 次时，其性能已经趋于当前结构的前馈神经网络模型的性能极限。而 0.1 的损失值大小也说明涡轮部分前馈神经网络模型的判断精准度足以满足项目要求。

同理压缩机部分通过 2573 条条数据样本输入模型进行预测，每条数据样本由四个关键传感器参数组成，即温度（temperature）、压力（pressure）、振动（vibration）和湿度（humidity），这些数据以一维张量的形式输入模型。模型输出的预测结果与每条样本的实际故障标签（faulty）进行对比分析，得到压缩机部分的故障判断准确率为 97.35%。压缩机部分前馈神经网络模型随每轮模型训练时的损失值如下图图 3.2 压缩机部分模型损失值随训练轮次变化图所示：

在图 3.2 中可以观察到，压缩机部分前馈神经网络模型的损失值随训练轮次的增大，基本上呈现下降趋势，偶尔会出现上涨，这属于模型训练中的正常波动。可以看到直到训练轮次到 47 轮时，模型的损失值到最小。与图 3.1 相同的是，模型的损失值在历轮次 1 到 3 时是迅速下降的，随后随模型训练轮次的增加而缓慢减小。这表明模型在前 3 个轮次已经基本训练完成，后续训练只是让模型的判断精准度能达到当前模型结构的极限。同时压缩机部分神经网络模型的损失值在训练轮次 51 此时已经小于 0.1。压缩机部分神经网络模型的判断精准度已经足以满足项目的要求。




图 3.2 压缩机部分模型损失值随训练轮次变化图

同理泵部分通过 2534 条 (temperature,pressure,vibration,humidity) 样式的一维张量输入模型得到的结果与其本身的 (faulty) 值相对比, 得到泵部分的故障判断准确率为 95.65%。泵部分前馈神经网络模型随每轮模型训练时的损失值如下图图 3.3 泵部分模型损失值随训练轮次变化图所示:




图 3.3 泵部分模型损失值随训练轮次变化图

在图 3.3 可以观察到，泵部分神经网络模型的损失值随模型的训练轮次增加而下降，其下降曲线一开始较急，随后就逐渐趋于平缓下降吗，最后神经网络模型的损失值在 0.1 附近，泵部分神经网络模型的判断精准度已经足以满足项目的要求。

3.2 基于音频模态的机械部位检测模型的设计与实现

音频信息模态判断机械部位模型是采用循环神经网络模型来训练完成的。循环神经网络是一类神经网络架构，专门用于处理序列数据，能够捕捉时间序列或有序数据的动态信息，能够处理序列数据，如文本、时间序列或音频。循环神经网络在自然语言处理（NLP）、语音识别、时间序列预测等任务中有着广泛的应用。循环神经网络模型的关键特性是其能够保持隐藏状态（hidden state），使得网络能够记住先前时间步的信息，这对于处理序列数据至关重要。基于其特性本系统是通过训练循环神经网络模型来实现根据音频判断机械部位功能的。

3.2.1 数据搜集

此部分所需要的数据集是在 MIMI 数据集上下载的，其单个数据为时间长度为 10 秒，数据大小为 2.44M，命名格式为八位数字且连续按 1 为间隔增长的 wav 格式音频文件。一个大机械部位文件夹包含 abnormal 文件夹和 normal 文件夹。其中 abnormal 文件夹中存储的为机械部位有故障的音频数据，normal 文件夹中存储的是机械部位是正常发音的音频数据。

3.2.2 数据清洗与 MFCCT 处理

因为音频数据不能直接使用所以需要使用 `torchaudio.load()` 函数来将音频文件转化成二维矩阵。因为 MIMI 数据集的音频数据是 8 声道采集的，频率为 16K HZ，因此 `torchaudio.load()` 函数返还值的二维矩阵为 $(8, X)$ ，其中 X 为波形张量。同时要利用 `waveform = torch.mean(waveform, dim=0, keepdim=True)` 函数来将 $(8, X)$ 形状的张量数据转化成 $(1, X)$ 形状的张量数据。其中 `dim = 0` 表示沿 0 维对张量做平均值，`keepdim=True` 参数的作用是保持张量的维度数量不变，列如，如果原始张量形状是 (C, T) ，经过 `dim=0` 和 `keepdim=True` 后，形状变为 $(1, T)$ ，而不是 $(T, 1)$ 。之所以要将音频数据转换成形状为 $(1, X)$ 的张量，是因为要对音频数据做 MFCCT 处理。MFCCT (Multi-Scale Feature Fusion with Channel and Temporal Attention) 是一种结合了多尺度特征融合、通道注意力机制以及时间注意力机制的技术，主要用于提升深度学习模型在处理序列数据（如音频、视频、时间序列等）时的性能。MFCCT 可以增强音频数据的特征表示能力，通过融合不同尺度的特征信息，MFCCT 能够捕捉到数据中的局部和全局上下文信

息。这种多尺度的特征表示有助于模型更好地理解数据的复杂结构，从而提高特征表示的丰富性和鲁棒性。同时对于序列数据，时间注意力机制能够捕捉时间维度上的依赖关系，使模型能够关注到序列中不同时间步的重要性。这样做有助于模型更好地理解序列数据的动态变化，提高特征表示的时序敏感性。通过对音频数据进行 MFCCT 处理，能加强音频数据的特征表示能力，能够显著提升模型在分类和识别任务中的准确率。例如，在语音识别、图像分类等任务中，MFCCT 处理可以帮助模型更准确地识别出不同的类别。并且 MFCCT 处理通过引入多尺度特征融合和注意力机制，使模型能够更好地适应不同的数据分布和场景。这有助于增强模型的泛化能力，使其在面对新数据时也能保持较好的性能。

在此项目中，MFCCT 处理的参数配置为采样率 16kHz、帧长 400 点（25ms）、帧移 160 点（10ms），生成 40 维梅尔滤波器组。通过 T.MFCC 模块提取基础 MFCC 特征，其输出维度为 $(1, 40, T')$ ，其中 T' 为时域帧数。此过程通过非线性梅尔尺度映射，能有效压缩频谱分辨率并强化语音感知关键频带。为捕捉语音信号的动态演化特性，引入双阶差分计算模块。首先通过 ComputeDeltas 计算一阶差分（ Δ -MFCC），表征特征变化速率；再次应用差分计算获得二阶差分（ $\Delta\Delta$ -MFCC），反映加速度信息。该过程通过：

$$\Delta_t = \frac{\sum_{n=1}^N n(c_{t+n} - c_{t-n})}{2 \sum_{n=1}^N n^2} \quad (3-9)$$

实现局部时序上下文建模，其中 $N=2$ 为差分窗口半径， C_t 为第 t 帧 MFCC 系数。最后针对原始输出维度 $(1, 40, T')$ ，通过维度置换操作 `permute(0,2,1)` 转换为 $(1, T', 120)$ ，将时序维度置于第二维以适配后续循环神经网络的特征输入需求。最终通过通道拼接：

$$F = [C; \Delta C; \Delta\Delta C] \in \mathbb{R}^{T' \times 120} \quad (3-10)$$

生成包含静态频谱（40 维）、一阶动态（40 维）、二阶动态（40 维）的三维特征张量。特别地，通过使用 `.squeeze(0)` 函数操作通过移除冗余的批次维度（由单声道输入 $C \in \mathbb{R}^{1 \times T' \times 40}$ 压缩至 $\mathbb{R}^{T' \times 120}$ ），在保持特征连续性的同时确保与下游模型输入要求的维度兼容性。最后将单条音频数据清洗成形状为 $(T, 120)$ 的张量。数据整理成如下表 3.2 数据格式表和表 3.3 数据格式续表所示，1 表示机械部位是涡轮，0 表示机械部位是泵，2 表示部位是压缩机。前面的是音频文件路径，通过 `waveform, sr = torchaudio.load(self.file_paths[idx])` 函数将音频数据转化成二维矩阵，再将 `waveform` 进行 MFCCT 处理，得到存储 $(T, 120)$ 的张量的列表和对应部位代表数列表。

表 3.2 数据格式表

文件路径	音频对应的机械部位数
<code>./fan/normal/00000000.wav</code>	1
----	----
<code>./fan/abnormal/00000000.wav</code>	1

表 3.3 数据格式续表

文件路径	音频对应的机械部位数
——	——
./pump/normal/00000000.wav	0
——	——
./pump/abnormal/00000000.wav	0
——	——
./compressor/normal/00000000.wav	2
——	——
./compressor/abnormal/00000000.wav	2
——	——

3.2.3 循环神经网络模型的训练

在本工业设备故障检测项目中音频信息判断是否故障模型的设计与实现中，我使用 LSTM（长短时记忆网络）作为循环神经网络的基本构件，并且采用了双向 LSTM 结构。LSTM 是 RNN（循环神经网络）的一种变体。可以查看第二章核心技术概要中的第二小结循环神经网络模型了解详情。LSTM 是专门设计用于解决传统 RNN 在处理长序列数据时面临的梯度消失和梯度爆炸问题，从而更有效地捕捉长期依赖关系。LSTM 单元通过引入门控机制，包括输入门、遗忘门、输出门以及细胞状态，来精细控制信息的流动和记忆。输入门决定哪些新信息被加入细胞状态，遗忘门决定哪些旧信息被丢弃，输出门则控制细胞状态中哪些信息被用于生成当前输出。细胞状态作为信息传输的“高速公路”，贯穿整个序列，使得 LSTM 能够保持对长期上下文的记忆。每个 LSTM 单元通过输入门 I_t ，遗忘门 F_t ，输出门 O_t 及细胞状态 C_t 的协同控制，实现长期依赖的捕获，长短时记忆神经网络结构中各组件模型的数学表达式如下：

输入门 I_t :

$$I_t = \sigma(X_t W_{ih}^I + H_{t-1} W_{hh}^I + b_{ih}^I) \quad (3-10)$$

遗忘门 F_t :

$$F_t = \sigma(X_t W_{ih}^F + H_{t-1} W_{hh}^F + b_{ih}^F) \quad (3-11)$$

输出门 O_t :

$$O_t = \sigma(X_t W_{ih}^O + H_{t-1} W_{hh}^O + b_{ih}^O) \quad (3-12)$$

候选记忆细胞:

$$\tilde{C}_t = \sigma(X_t W_{ih}^{Ct} + H_{t-1} W_{hh}^{Ct} + b_{ih}^{Ct}) \quad (3-13)$$

记忆细胞 C_t :

$$C_t = f_t \times C_{t-1} + i_t \times \tilde{C}_t \quad (3-14)$$

其中 $\sigma()$ 为 sigmoid 激活函数, $\odot$ 表示逐元素相乘, 权重矩阵 W 与偏置 b 通过训练优化。LSTM 向前传播公式为输入序列 $X = \{x_1, x_2, \dots, x_T\}$ 依次通过前向 LSTM 层, 生成前向隐藏状态序列 $h_1, h_2, \dots, h_T$ 。

相较于单层 LSTM 按照时间顺序处理序列数据, 仅能利用过去的信息来预测当前或未来的状态。我们采用的双层 LSTM 可以同时利用过去和未来的信息, 从而更全面地理解序列数据的上下文。这种特性使得双向 LSTM 在需要全局上下文感知的任务中表现尤为出色。在一些单层 LSTM 不好完成的任务中表现优秀。列如, 在语音识别中的音素分类、自然语言处理中的词性标注和命名实体识别等任务中, 采用双向 LSTM 建模, 模型能够更准确地捕捉序列中的长期依赖关系和局部特征, 进而提升模型整体的性能, 且模型表现出更强的鲁棒性, 能够更好地适应不同长度的输入序列。

在本工业设备故障监测系统项目音频信息判断是否故障模型的设计与实现中通过采用双向 LSTM, 模型能够同时学习到音频信号中的前后时序信息。对于每一个时间步, LSTM 会处理当前输入以及前一个时间步的隐藏状态, 并将其与未来时间步的隐藏状态进行结合, 以捕捉信号中的长期依赖。双向 LSTM 的传播公式相较于单向 LSTM 公式更加复杂, 如下:

输入序列 $X = \{x_1, x_2, \dots, x_T\}$ 依次通过前向 LSTM 层, 生成前向隐藏状态序列 $h_1, h_2, \dots, h_T$ 。

反向序列 $X_{\text{rev}} = \{x_T, \dots, x_1\}$ 通过后向 LSTM 层, 生成后向隐藏状态序列 $h_1, h_2, \dots, h_T$ 。

最终输出为前后向隐藏状态的拼接: $h_t = h_t \oplus h_t$, 其中 $\oplus$ 表示张量拼接操作。

在本工业设备故障监测系统项目音频信息判断是否故障模型的设计与实现中, 模型的输入数据形状为上文清洗的数据形状 (T,120), 因此循环神经网络模型的输入特征数设为 `input_size = 120`, 隐藏层按正常训练设为 `hidden_size = 128`。最后全连接层代码为 `self.fc = nn.Linear(hidden_size * 2, num_classes)`, 因为采用了双向 LSTM, 所以输入的大小为隐藏层 (hidden) 大小的两倍, 其输出大小为 `num_classes` (前面设置的类别数), 列如 `num_classes = 2`, 其结果就在 0 和 1 中出现。此循环神经网络模型的原始输出结果为一个形状为 (1,2) 的张量, 需要对原始输出结果做归一化处理。可以使用 `softmax()` 函数来进行归一化处理。列如, 循环神经网络模型的原始输出为 `output`, 则可以使用函数 `probs = torch.softmax(output, dim=1)` 来实现归一化。 `Class = probs.argmax().item()` 来得到循环神经网络模型设定的输出结果。

3.2.4 循环神经网络模型训练结果

在完成循环神经网络 (Recurrent Neural Network, RNN) 模型的数据集搜集、清洗以及特征提取处理 (如使用 MFCC 进行特征提取) 后, 进入了模型参数的设置与训练阶段。在本实验中, 针对任务需求和数据特点, 对循环神经网络模型中各个关键参数进行

了合理配置和设置，并在实验过程中逐一验证了这些设置的有效性。例如，在隐藏层神经元数量的选择上，综合考虑了模型的学习能力与计算复杂度，设置为 128 个神经元；学习率设置为 0.001，以保证模型在收敛速度与稳定性之间达到较好的平衡；优化器选择了 Adam 优化器，其自适应学习率的特点使得模型在训练过程中能更高效地找到最优解。此外，模型的损失函数采用了交叉熵损失函数（Cross-Entropy Loss），这是分类问题中广泛使用的一种标准损失函数，能够很好地评估模型的输出概率分布与真实标签之间的差异。完成参数设置后，将预处理好的音频特征数据输入到构建好的循环神经网络中进行迭代训练。模型训练完成后，对模型的性能进行了系统评估，特别是对其分类准确率进行了计算。准确率的计算方式为：将模型在测试集中的正确预测次数累加后除以总测试次数，并乘以 100%，得到百分比形式的准确率。本实验在使用未经训练的新音频样本组成的测试集上对模型进行评估，最终得出该循环神经网络模型在判断音频对应机械部位方面的准确率达到 98.88%，表明模型在该任务上具有非常高的判别能力和泛化能力。

基于音频判断是哪个机械部位的循环神经网络模型的损失值随训练轮次的变化如下图所示 3.4 判断机械部位循环神经网络模型的损失值变化图所示。由于循环神经网络模型较前馈神经网络模型来说更加复杂，所以还绘制了循环神经网络模型判断的准确率随循环神经网络模型训练轮次变化的曲线，这里的准确率是指音频训练集输入模型得到的准确率，如下图所示 3.5 判断机械部位循环神经网络模型的准确率变化图所示。由我自己训练循环神经网络模型的实际实验得知，训练轮次大于 9 次时，很容易出现训练的循环神经网络模型过于拟合的情况，因此循环神经网络模型的训练轮次我定在 9 轮。




图 3.4 判断机械部位循环神经网络模型的损失值变化图




图 3.5 判断机械部位循环神经网络模型的准确率变化图

由图 3.4 可以得知，循环神经网络模型的损失值随模型训练次数的增加，基本上是呈现下降的趋势。在模型训练轮次为 9 次时，模型的损失值已经小于 0.1，趋近于 0.03。这个损失值对于模型的训练来说，已经够小了，代表模型的判断功能可以满足项目的需求。同时由图 3.5 可以得知，循环神经网络模型的判断准确率随模型训练轮次的增加，基本上是呈现上升趋势。在模型训练轮次为 9 次时，其模型判断的准确率以及无限趋近于 100%，达到 98.7%。这样的判断准确率已经可以满足项目对判断机械部位准确率的需求。

3.3 基于音频模态的故障检测模型的设计与实现

音频信息模态判断故障模型是采用循环神经网络模型来训练完成的。循环神经网络是一类神经网络架构，专门用于处理序列数据，能够捕捉时间序列或有序数据的动态信息，能够处理序列数据，如文本、时间序列或音频。循环神经网络在自然语言处理(NLP)、语音识别、时间序列预测等任务中有着广泛的应用。循环神经网络模型的关键特性是其能够保持隐藏状态（hidden state），使得网络能够记住先前时间步的信息，这对于处理序列数据至关重要。基于其特性本系统在实现根据音频判断机械部位是否故障功能方面使用循环神经网络来训练模型。

3.3.1 数据清洗

此部分所需要的数据集是在 MIMI 数据集上下载的，其单个数据为时间长度为 10 秒，数据大小为 2.44M，命名格式为八位数字且连续按 1 为间隔增长的 wav 格式音频文件。

有 2 个不同的机械部位文件夹，每一个机械部位文件夹包含 **abnormal** 文件夹和 **normal** 文件夹。其中 **abnormal** 文件夹中存储的为机械部位有故障的音频数据，**normal** 文件夹中存储的是机械部位是正常发音的音频数据。

3.3.2 数据清洗与 MFCCT 处理

在构建基于音频模态的故障检测模型与机械部位识别模型过程中，前期的数据清洗与特征提取处理是十分关键的步骤。具体来说，两者在数据处理流程上基本一致，主要区别在于数据标签的含义不同。无论是进行故障检测还是机械部位识别，都需要对原始音频数据进行预处理，以提取出可用于模型训练的有效特征。其中，音频首先会被统一切割成合适的时长和格式，然后通过 MFCCT 技术对其进行特征提取。最终将音频数据给转化清洗成形状为 (T,120) 的列表，唯一不同的是表中数据对应的格式不同。如下表 3.4 涡轮数据格式对应表, 表 3.5 泵数据格式对应表和表 3.6 压缩机数据格式对应表所示，在表中文件路径列中表示音频储存在项目中的相对路径，机械部位是否故障对应数字列中 0 表示机械部位是正常的，1 表示机械部位发生故障。

表 3.4 涡轮数据格式对应表

文件路径	机械部位是否故障对应数字
./fan/normal/00000000.wav	0
----	----
./fan/abnormal/00000000.wav	1
----	----

表 3.5 泵数据格式对应表

文件路径	机械部位是否故障对应数字
./pump/normal/00000000.wav	0
----	----
./pump/abnormal/00000000.wav	1
----	----

表 3.6 压缩机数据格式对应表

文件路径	机械部位是否故障对应数字
./compressor/normal/00000000.wav	0
----	----
./compressor/abnormal/00000000.wav	1
----	----

3.3.3 循环神经网络模型

基于音频模态的故障检测模型设计与实现中的循环神经网络模型的设计与实现与前文基于音频模态的机械部位检测模型设计与实现中的循环神经网络模型的设计与现实相似。唯一不同的是在此部分需要训练三个不同机械部位的循环神经网络模型。分别为涡轮机械部位判断是否发生故障的循环神经网络模型，压缩机机械部位判断是否发生故障的循环神经网络模型和泵机械部位判断是否发生故障的循环神经网络模型。这三个模型的输入都是经过 MFCCT 处理的音频数据，是形状为 $(T, 120)$ 的张量。其输出结果 0 表示当前机械部位未发生故障，输出结果 1 表示当前机械部位出现故障。

3.3.4 循环神经网络模型训练结果

在完成循环神经网络模型的数据集搜集，数据的清洗与 MFCCT 处理后，详细说明了模型中各个参数设置的原因和其设置的大小，再将数据输入进循环神经网络模型来迭代训练。在循环神经网络模型训练完成后，对循环神经网络模型进行准确率的计算，计算方法为累加模型正确预测的次数与总测试次数做百分比。得出判断涡轮机械部位是否故障的循环神经网络模型的准确率为 92.48%，这里准确率使用未经训练的新音频做数据集得到的准确率。

基于音频判断涡轮是否故障的循环神经网络模型的损失值随训练轮次的变化如下图 3.6 判断涡轮是否故障的循环神经网络模型的损失值变化图所示。由于循环神经网络模型较前馈神经网络模型来说更加复杂，所以还绘制了循环神经网络模型判断的准确率随循环神经网络模型训练轮次变化的曲线，这里的准确率是指音频训练集输入模型得到的准确率，如下图图 3.7 判断涡轮是否故障的循环神经网络模型的准确率变化图所示。由我自己训练循环神经网络模型的实际实验得知，训练轮次大于 9 次时，很容易出现训练的循环神经网络模型过于拟合的情况，因此循环神经网络模型的训练轮次我定在 9 轮。

根据图 3.6 所示，可以看出用于判断涡轮机械部位是否故障的循环神经网络(RNN)模型在训练过程中，其损失值(Loss)随模型训练轮次的增加基本呈现出持续下降的趋势。这种下降趋势表明模型在不断优化参数、逐步学习训练数据中的规律和特征。在训练达到第 9 轮时，模型的损失值已显著降低至 0.023，说明模型在对训练数据的拟合效果良好，误差极小，模型训练过程稳定、正常，未出现训练中断、异常波动或明显的过拟合趋势。进一步地，从图 3.7 中可以观察到，该 RNN 模型的准确率随着训练轮次的增加而不断上升。准确率的提升表明模型的预测能力持续增强，能够更准确地判断涡轮部位是否存在故障。在第 9 轮训练结束时，模型的准确率已达到 99.98%，几乎接近满分水平。该准确率远高于多数实际工业项目中的最低性能标准，完全满足本项目对涡轮部位故障判断的准确性要求。



图 3.6 判断涡轮是否故障的循环神经网络模型的损失值变化图




图 3.7 判断涡轮是否故障的循环神经网络模型的准确率变化图

同理，在完成基于音频检测压缩机部位是否故障的循环神经网络模型训练后，对此循环神经网络模型进行准确率的计算，计算方法为累加模型正确预测的次数与总测试次数做百分比。得出判断压缩机机械部位是否故障的循环神经网络模型的准确率为 87.96%，这里准确率使用未经训练的新音频做数据集得到的准确率。

基于音频判断压缩机是否故障的循环神经网络模型的损失值随训练轮次的变化如下图所示 3.8 判断压缩机是否故障的循环神经网络模型的损失值变化图所示。由于循环神经网络模型较前馈神经网络模型来说更加复杂，所以还绘制了循环神经网络模型判断的准确率随循环神经网络模型训练轮次变化的曲线，这里的准确率是指训练集音频输入模型得到的准确率，如下图所示 3.9 判断压缩机是否故障的循环神经网络模型的准确率变化图所示。同理，基于音频判断压缩机是否故障的循环神经网络模型的训练轮次定在 9 轮。




图 3.8 判断压缩机是否故障的循环神经网络模型的损失值变化图

根据图 3.8 所示，用于判断压缩机机械部位是否故障的循环神经网络（RNN）模型在训练过程中，其损失值整体随着训练轮次的增加呈现出明显的下降趋势。这说明模型在不断优化的过程中，能够逐步减少预测结果与真实标签之间的误差，表明其在学习训练数据特征方面表现良好。然而，在训练达到第 9 轮时，损失值出现了一个小幅度的回升，突然上升至约 0.1 左右。尽管如此，这种情况在神经网络的训练过程中属于正常现象，可能是由于随机梯度下降过程中出现的误差震荡，或者是小批量样本引发的临时波动。这种跳动并不意味着模型性能下降，也不会影响整体训练效果，仍处于模型训练的合理范围内，说明训练过程整体稳定可控。进一步分析图 3.9，可以发现该 RNN 模型的准确率在整个训练过程中持续提升，表现出良好的收敛趋势。特别是在第 9 轮训练完成时，模型的准确率已达到 98.23%，虽然略低于完全接近 100%的理想状态，但依然远高于大多数工业项目中对故障检测模型的性能要求。这一结果充分证明了所构建的循环神经网络模型在识别压缩机部位是否存在故障方面具有较高的可靠性与实用性，也说明模型在本项目中的应用前景广阔，具备较强的推广价值。




图 3.9 判断压缩机是否故障的循环神经网络模型的准确率变化图

同理，在完成基于音频检测泵部位是否故障的循环神经网络模型训练后，对此循环神经网络模型进行准确率的计算，计算方法为累加模型正确预测的次数与总测试次数做百分比。得出判断泵机械部位是否故障的循环神经网络模型的准确率为 93.28%，这里准确率使用未经训练的新音频做数据集得到的准确率。

基于音频判断泵是否故障的循环神经网络模型的损失值随训练轮次的变化如下图 3.10 判断泵是否故障的循环神经网络模型的损失值变化图所示。由于循环神经网络模型较前馈神经网络模型来说更加复杂，所以还绘制了循环神经网络模型判断的准确率随循环神经网络模型训练轮次变化的曲线，这里的准确率是指训练集音频输入模型得到的准确率，如下图图 3.11 判断泵是否故障的循环神经网络模型的准确率变化图所示。同理，基于音频判断压缩机是否故障的循环神经网络模型的训练轮次定在 9 轮。

由图 3.10 可以得知，判断泵机械部位是否故障的循环神经网络模型的损失值随模型训练的轮次增加，基本上呈现下降趋势。在模型训练轮次达到 9 次时，模型的损失值已经下降到 0.1 以下，这样的损失值变化趋势代表着模型在正常训练。由图 3.11 可以得知，判断压缩机机械部位是否故障的循环神经网络模型的准确率随模型训练轮次的增加，基本上呈现上升趋势。模型判断的准确率在轮次为 9 次时，模型判断的准确率却下降到 95% 以下，为 93.37%。虽然低于完全接近 100% 的理想状态，但依然远高于大多数工业项目中对故障检测模型的性能要求。这一结果充分证明了所构建的循环神经网络模型在识别泵部位是否存在故障方面具有较高的可靠性与实用性，也说明模型在本项目中的应用前景广阔，具备较强的推广价值。




图 3.10 判断泵是否故障的循环神经网络模型的损失值变化图




图 3.11 判断泵是否故障的循环神经网络模型的准确率变化图

3.4 本章小结

在本章中，对基于文本信息判断机械是否故障这一功能需求，设计和实现了三个前馈神经网络模型，来判断三种机械部位是否故障。同时对这三个前馈神经网络模型是如何进行数据搜集与清洗，数据是如何在模型中训练与训练好的模型的性能进行了详细的讲解和分析。对基于音频信息判断是哪个机械部位这一功能需求，设计和实现了一个循环神经网络模型，来判断音频是属于哪个机械部位的。同时对这一个循环神经网络模型是如何进行数据搜集与清洗，数据是如何在模型中训练与训练好的模型的性能进行了详细的讲解和分析。对基于音频信息判断机械是否故障这一功能需求，设计和实现了三个循环神经网络模型，来判断三种机械部位是否故障。同时对这三个循环神经网络模型是如何进行数据搜集与清洗，数据是如何在模型中训练与训练好的模型的性能进行了详细的讲解和分析。

第4章 工业设备故障检测系统的设计与实现

工业设备故障检测系统的实现是本文研究的重点，本章将在完成前馈神经网络模和循环神经网络模型训练的基础上，完成工业设备故障检测系统的需求分析，并根据需求分析完成工业设备故障检测系统可视化页面功能的设计与其对应页面可视化的实现。

4.1 项目需求分析

对工业设备故障系统进行需求分析前，我们首先要明白什么是需求分析。学者们对需求分析的定义为：需求分析也称为软件需求分析、系统需求分析或需求分析工程等，是开发人员经过深入细致的调研和分析，准确理解用户和项目的功能、性能、可靠性等具体要求，将用户非形式的需求表述转化为完整的需求定义，从而确定系统必须做什么的过程。由需求分析的定义可知需求分析是连接用户需求与系统实现的桥梁，需求分析通过科学方法将模糊的“需要”转化为清晰的“解决方案”，一个成功的需求分析可以为项目成功奠定基础。一个成功的需求分析能指导系统设计，为架构选择、模块划分提供理论指导，确保系统的可视化界面和功能设计符合用户需求，并且需求分析可以帮助识别并剔除冗余或矛盾的需求，避免开发不必要的功能，降低资源浪费。从而确定项目系统功能的边界，避免在开发过程中再对项目功能进行扩展和修改，造成不必要的资源浪费。

通过对目标用户进行调查，我为工业设备故障检测系统的可视化设计了以下页面。用户登录页面，用户登录页面满足了客户对工业设备故障检测系统安全性的需求。通过设置用户登录页面可以防止没有权限的用户对工业设备故障检测系统进行浏览，有效防止工业设备信息的丢失。系统用户注册页面，系统用户注册页面满足了用户对有权限登录系统用户录入的简便化和可视化操作的需求。通过完成系统用户注册页面的可视化能减少操作系统的工人的学习成本，使其不用完成对系统后端代码的了解与学习，直接在系统用户注册页面进行简单的操作来完成添加权限用户的目的。系统主页面，系统主页面满足用户对系统功能了解的需求。本工业设备故障检测系统的主页面通过设计简洁明了的页面能有效减少操作工业设备故障检测系统工人的认知负荷、提升其操作系统的效率、增强客户的满意度。工业设备状态检测页，工业设备状态检测页满足了用户对本系统的核心功能需求，即判断工业设备是否故障的需求。在工业设备状态检测页操作系统的工人可以根据工业设备状态检测页面的提示填写各种数据，在填写数据完成后点击提交数据按钮完成对数据的上传。工业设备状态检测结果页，工业设备状态检测结果页满足了用户对本系统的核心功能需求，即判断工业设备是否故障的需求。工业设备状态检测结果页根据用户输入的数据返还此数据对应的机械部位，机械部位是否故障与对上述判断

的判断准确概率。根据工业设备状态检测结果页返还的数据系统操作员可以知晓工业设备的故障部位与工业设备是否故障。这样工人去检修是能更快确定工业设备故障的部位从而更快速的完成对工业设备的检修。压缩机页，压缩机页通过完成对前馈神经网络模型（判断机械部位是否故障）检测结果和循环神经网络模型（判断机械部位是否故障）检测结果的图形可视化，清晰明确的展现了模型对机械部位是否故障判断的准确率，满足了客户对知晓模型准确率要求是否达标的需求。泵页，泵页通过完成对前馈神经网络模型（判断机械部位是否故障）检测结果和循环神经网络模型（判断机械部位是否故障）检测结果的图形可视化，清晰明确的展现了模型对机械部位是否故障判断的准确率，满足了客户对知晓模型准确率要求是否达标的需求。涡轮页，涡轮页通过完成对前馈神经网络模型（判断机械部位是否故障）检测结果和循环神经网络模型（判断机械部位是否故障）检测结果的图形可视化，清晰明确的展现了模型对机械部位是否故障判断的准确率，满足了客户对知晓模型准确率要求是否达标的需求。

4.2 系统主要功能的设计与实现

4.2.1 多模态故障检测的实现逻辑

本文中工业设备故障检测系统不同于以往基于单模态信息的故障检测系统，本系统是基于音频和文本信息这两个信息模态来一起判断机械部位是否故障。在系统的设计中本文采用对基于音频模态的故障检测模型的结果和基于文本模态的故障检测模型的结果做余弦相似度计算，通过余弦相似度计算的结果来完成对应机械部位是否故障的判断。具体对数据的处理流程可以参考下图 4.1 故障检测流程图理解。




图 4.1 故障检测流程图

4.2.2 故障检测功能输入页的设计与实现

工业设备故障检测系统的故障检测功能是由两个前端页面共同实现的，其功能实现的流程图可以参考下图 4.2 故障检测功能实现流程图：




图 4.2 故障检测功能实现流程图

工业设备故障检测系统的故障检测输入页从上到下可以分为三个部分。首先是页面的顶部区域，这部分主要用于展示系统的标语或标题，明确告知用户当前界面属于工业设备故障检测系统，起到指引和说明的作用，增强系统的专业性和用户的信任感。页面的中间部分是该故障检测页面的核心区域，占据了页面的最大比例。这里包含了四个数字信息输入框和一个音频文件上传框，分别对应工业设备运行状态的关键参数。具体而言，四个数字输入框依次为温度信息输入框、压力信息输入框、振动信息输入框和湿度信息输入框，用户可根据实际设备采集到的传感器数据填写相应数值。同时，还设有一个音频文件上传框，用于上传机械运行时录制的音频文件，这些文本模态信息和音频模态信息能一起进行对机械是否故障进行判断，这样系统能提供给用户更精准的故障诊断分析。系统故障检测页的下面部分由两个按钮构成，分别为提交检测数据按钮和返回系统主页面按钮。工业设备故障检测系统的故障检测页面的具体情况可以参考下图 4.3 工业设备故障检测系统故障检测输入页图所示。

工业设备故障检测系统

温度 (°C):
请输入设备温度值

压力 (MPa):
请输入设备压力值

震动 (mm/s):
请输入设备震动值

湿度 (%RH):
请输入环境湿度值

设备运行音频:

选择文件 未选择文件

支持格式: WAV, MP3, OGG (最大50MB)

提交检测数据 返回主页面

图 4.3 工业设备故障检测系统故障检测输入页图

工业设备故障检测系统故障检测页的实现过程,故障检测页面通过 form 表单提交上述信息到 django 项目的后端,在后端 views.py 页面中利用 post 接收上述文本信息和音频信息。利用 save() 函数将音频储存在项目内 audio 文件夹(在 django 应用中创建 audio 文件夹,方便后续为使用音频文件寻址)中。通过音频文件地址读取音频文件,对音频文件做 MFCCT 处理,使用函数生成音频相对应的 MFCCT 音频波形图图片,将图片储存在 django 项目中 static 文件夹中的 img 文件夹中。

在 django 项目中,配置神经网络模型使用环境。由于第三章训练神经网络模型时不在 django 项目中,因此想在 django 项目中使用神经网络模型需要为神经网络模型配置使用环境。第一步,在训练神经网络模型时对模型的保存需要使用轻量化模型保存方式。即使用 torch.save(model.state_dict(), 'model.pth')来保存模型,在上述函数中 model 为训练模型的名称,model.pth 为保存完文件的名称。使用这种方法保存的是神经网络模型的状态字典,这样做比保存完整的神经网络模型更加灵活,在再次使用模型时兼容性更好。列如,在 django 项目中调用神经网络模型时,完整保存的神经网络模型在调用是不兼容而字典保存的神经网络模型则可以正常调用。第二步,在 django 项目中 views.py 文件的

同级目录中创建 `my_model.py` 文件。将训练神经网络模型时定义过的模型再在 `my_model.py` 文件中定义，在 `views.py` 文件中引用 `my_model.py` 文件中的模型，这样做是因为神经网络模型的轻量化保存的只有模型的训练参数在调用神经网络模型时需要再次定义相同的神经网络模型结构。同时由于训练神经网络模型项目与工业设备故障检测项目使用的是同一个虚拟环境，因此不需要在工业设备故障检测系统这个 `django` 项目中再次下载 `PyTorch` 框架。

工业设备故障检测系统实现故障检测页面功能函数的具体逻辑。前面已经介绍过了如何在函数中接收故障检测页面中的数据和如何在函数中配置好调用神经网络模型的环境，现在继续讲解下一步。在函数中已经对音频文件做完 `MFCCT` 处理，得到了一个形状为 $(T, 120)$ 的张量，再使用 `unsqueeze(dim=0)` 函数将其转化形状为 $(1, T, 120)$ 的张量。这是因为当时训练的循环神经网络模型的输入要求为形状为 $(X, X, 120)$ 的三维张量，括号中的 X 表示任意数。将转化好的张量输入前文介绍过的循环神经网络模型（判断机械部位），得到了一个形状为 $(1, 2)$ 的二维张量，这里命名为 `probs`。使用 `softmax()` 函数来解析循环神经网络模型输出的结果 `probs`，再对结果使用 `argmax()` 函数便可以得到但是对循环神经网络模型定义时模型类别对应的输出数 `class_id`（如，此音频为泵机械部位运行发出的声音，对此音频做完上述处理后输入模型，在对模型的结果进行解析，得出当时对模型定义时泵对应的数字）。还可以继续使用 `probs[0, class_idx].item()` 来得到模型输出结果的可信度。对模型的结果进行 `if` 判断，分泵，涡轮，压缩机三类判定，现以泵这一判断做例子讲解。设置字典储存泵这机械类型的信息和对应结果的可信度。同理将音频信息做完 `MFCCT` 处理的输入到循环神经网络模型（判断泵机械部位是否故障的模型）中，在对结果进行解析，得到是否故障对应的结果。再将前文提到的温度，压力，震动和湿度这四个浮点型数据，用一个形状为 $(1, 4)$ 的向量保存。输入到前文提到过的前馈神经网络模型（判断泵部位是否故障的模型），得到一个在 0 到 1 间的数据。为了将这两个模型的结果与机械部位是否故障这个结果相映射，可以使用余弦相似度^[32]来计算这两个模型输出结果与现实中机械部位是否故障的关系，来实现神经网络模型结果与现实结果之间的一一对应。余弦相似度的计算公式如下：

$$\cos \theta = \frac{\sum_{i=1}^n (A_i \times B_i)}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}} \quad (4-1)$$

设置余弦相似度大于 0.8，判断现实结果与两个神经网络模型的结果一致，即系统判断出现故障，需要检修。小于 0.8，系统判断机械部位正常，不需要检修。将结果存入字典中，将字典传到故障检测结果页，向使用者展现工业设备故障检测系统判断的结果。其余的两个 `if` 判断与泵 `if` 判断的逻辑一致，不需要再讲述。

故障检测页面的缺陷。在工业设备故障检测系统项目的设计的最初构想中，故障检测页面的输入并非由使用者来输入数据，而是由工业设备对应的数据采集器直接将数据

输入到项目的后端来进行判断。由于缺少现实设备基础，现阶段只能添加此页面来做数据的输入。现在分享一下并入数据采集器此系统后端输入的实现逻辑，在后端设置每 3 秒将数据输入模型进行判断机械设备是否故障。对与温度，压力，震动和湿度这四个数据，将 3 秒钟的数据做平均数，再和音频数据一个输入模型做判断。

4.2.3 故障检测结果页的设计与实现

工业设备故障检测系统的故障检测结果页从上到下可以分为两个部位，第一个部位为机械部位故障诊断结果输出部分，此部分有 4 个输出，分别为机械部位识别，识别准确率，故障诊断结果，诊断准确率。第二个部分由一个返回故障检测页按钮组成。具体情况可以参考下图 4.5 故障检测结果页图。

图 4.5 故障检测结果页图展现的结果是由图 4.4 故障检测页输入图得到的，从图 4.4 故障检测页输入图中可以得知，温度，压力，震动和湿度都是与表中第五行数据吻合，前馈神经网络模型应该判断结果在 0 附近，即机械部位正常。同时可以得到音频输入文件是 pump 文件夹中 normal 文件夹中的数据，pump 文件夹表示音频属于泵运行时的音频数据，normal 表示为前一个文件夹中对应机械部位正常运行时发出的音频信息。由此可得，图 4.5 故障检测结果页图中的第一个部分输出为机械部位识别为泵，机械部位正常和对应的由故障检测页后端函数返回的字典中的值。预测结果与故障检测结果页图返回的结果相符，说明故障检测页后端的逻辑与模型的准确度都能得到保障。进行其他数据测试时，故障检测结果页图输出的结果也都与预测的结果相符合。




图 4.4 故障检测页输入图

故障检测结果页第二个部分按钮跳转功能是通过 `button` 标签来实现的，在 `button` 标签中添加 `onclick` 属性来指向 `django` 系统中 `urls.py` 页中路径，通过 `urls.py` 中的路径来与 `views.py`（视图文件）中的函数建立映射关系来实现点击按钮完成对应页面跳转功能的。




图 4.5 故障检测结果页图

4.3 系统次要功能的设计与实现

4.3.1 用户登入功能的设计与实现

在工业设备故障检测系统的可视化设计中，用户登录功能作为系统安全性的第一道防线，发挥着至关重要的作用。参考图 4.6 所示的用户登录功能流程图，整个登录流程从用户访问系统登录界面开始。用户需在该界面中输入预先注册的账号和密码，并点击登录按钮将信息提交至系统后台。后台服务器接收到用户输入的信息后，会与数据库中的用户信息进行匹配校验，验证账号与密码是否一致。如果验证通过，系统将授权该用户登录，并跳转至系统主页，用户即可在系统中执行如数据输入、故障检测等操作；若验证失败，则系统会提示账号或密码错误，用户需要重新输入正确的信息后再次提交验证请求。此流程确保了只有授权用户才能访问系统，为工业设备故障检测提供了安全可靠的前端入口。




图 4.6 用户登入功能流程图

在工业设备故障检测系统的可视化过程中，本系统设计了一个简单明了的用户登入页面，帮助用户减少学习使用本系统的成本，减少用户的认知负担。在这个页面中，从上到下设计了一个提示区（提示工业设备是否在线），两个输入区（一个为用户名输入区，一个为用户密码输入区），和一个提交信息的按钮（登录系统按钮）。具体情况如下图 4.7 用户登入页图所示：

用户登入页面可视化的实现过程，首先在 mysql 中设计权限用户表，其具体情况如下表 4.1 权限用户表所示：

表 4.1 权限用户表

User_name	Password	User_id
david	333333	1

在表中 user_id 为 key 键，设计为自动按加 1 增加。user_name 属性设置为 char 类型，长度为 16，Password 属性设置为 int 类型，长度为 16。user_name 和 Password 两个属性即可组合成复合主键，确定唯一一条记录。表中初始自带一组权限用户，其 user_name 为 david，Password 为 333333。用户在登录页面可以在用户名输入区输入 david，密码输入区输入 333333 来登入系统进入主页。在 mysql 数据库中建好表后，建立 Django 项目。在 Django 项目中创建第一个应用（app），在 setting.py 文件和 urls.py 文件中配置好环境和路径。在创建好的 app 中的视图文件中编写代码。在环境编译器中下载安装 PyMySQL 库，借助 pymysql 库来完成数据库 mysql 和 django 项目后端的链接。用户登录页面通过 form 表单提交将用户名和密码提交到项目后端的代码中，使用 post 接收提交的用户名和密码。再通过 pymysql 将用户名和密码同时和数据库中权限用户表中数据

相比，确定用户是否在表中。如果用户在数据库中的用户表中，则登录进系统主页；如果用户不在数据库表中的用户表中，则继续返回到用户登录页。



图 4.7 用户登入页图

4.3.2 系统主页的设计与实现

工业设备故障检测系统的主页从上到下可以分为三个部分，第一个部分为系统主页上方，向使用者提供了这个系统是做什么的信息，即本系统是工业设备故障检测系统。这部分主要用于展示系统的标语或标题，明确告知用户当前界面属于工业设备故障检测系统，起到指引和说明的作用，增强系统的专业性和用户的信任感。系统主页中间的部分占整个工业设备故障检测系统主页的大半，由 6 个按钮构成。分别为故障检测按钮，压缩机模型详细按钮，泵模型详解按钮，涡轮模型详解按钮，权限用户添加按钮和退出登录按钮。这 6 个按钮分别代表系统的 6 中不同的功能，会在对应的部分仔细讲解。系统主页下方部分为问题反馈途径，向系统的使用者提供问题反馈的途径，来解决系统使用者在使用系统是遇到的问题。工业设备故障检测系统主页的具体情况如下图 4.8 工业设备故障检测主页图所示：



4.8 工业设备故障检测主页图

工业设备故障检测系统主页采用模块化设计实现可视化交互。界面布局通过 HTML 结构化标签构建：顶部与底部宣传标语区域使用 `div` 容器进行语义化封装，结合 CSS 样式实现响应式布局；核心功能区由六个 `button` 标签构成操作入口，每个按钮配置 `onclick` 事件监听器，通过 Django 框架的 URL 路由机制绑定特定业务逻辑。当用户点击按钮时，触发预定义的路由路径，Django 的 `urls.py` 模块将该路径映射至 `views.py` 中对应的视图函数，完成数据处理与模板渲染，最终实现页面跳转。这种前后端解耦架构基于 MTV 设计模式，既保障了界面交互的流畅性，又通过路由配置与视图函数的分离设计，提升了系统的可维护性和扩展性。

4.3.3 权限用户添加功能的设计与实现

工业设备故障检测系统的权限用户添加功能，是维护系统安全的重要一环。参照图 4.9 的流程图，该功能通过严谨的步骤确保新用户的安全添加。用户首先访问权限用户添加页面，并输入账号、密码及密匙。密匙作为双重验证机制，密匙在向客户交付系统的同时给予客户。采用密匙机制有效防止了未授权用户的访问。数据随后被加密传输至后端进行验证，若密匙错误，则立即终止流程，保障系统安全。若验证通过，系统则将账号和密码安全地添加到数据库中。操作完成后，后端返回结果，前端显示添加成功消息，并引导用户重返系统主页。整个流程通过密匙验证、数据加密传输等安全措施，确保了只有授权人员才能创建新用户账户，防止未授权人员使用本工业设备故障检测系统。不仅确保了工业设备故障检测系统使用的安全性，还为工业设备故障检测系统后续功能的稳定运行提供了有力支持。




图 4.9 权限用户添加流程图

工业设备故障检测系统的权限用户添加页的整体架构设计与用户登录页面相似，区别在与页面下方的按钮功能不同。在权限用户添加页面中下方的按钮是确定添加用户。权限用户添加页的具体情况可以参考下图图 4.10 权限用户添加页图：

工业设备监测系统

● 用户注册

用户名
david

密码
.....

确定添加用户

图 4.10 权限用户添加页图

权限用户添加页面的实现逻辑为通过 form 表单提交输入的用户名和密码，在系统的后端通过 post 接收输入的数据，通过 PyMySQL 连接 mysql 数据库，将用户名和密码添加到表 4.1 权限用户表中。user_name 对应接收的用户名，Password 对应密码。这样在用户登入页即可使用此对用户名和密码登录系统。同时由于此页面在用户登录后才能解锁，也能在一定程度上保证工业设备故障检测系统的安全性。想更进一步保障安全性可以在密码输入框下添加一个密匙验证，密匙由购买工业设备故障检测系统的客户掌握，必需要密匙也输对才能将用户名和密码写入 mysql 数据库中的用户表中。

4.4.4 模型详解页的设计与实现

工业设备故障检测系统的模型详解页的实现流程图如下图 4.11 模型详解页流程图所示：





图 4.11 模型详解页流程图

工业设备故障检测系统的模型解析页有三个页面，分别为压缩机模型详解页面，泵模型详解页面和涡轮模型详解页面。模型详解页面有两个柱状图和页面底下的按钮构成。两个柱状图为前馈神经网络模型（判断机械部位是否故障）的准确率验证柱状图和循环神经网络模型（判断机械部位是否故障）的准确率验证柱状图。图形内的数据为训练神经网络模型是的数据，可以向客户展示模型的原始训练后用数据验证的准确率，具体情况如下图 4.12 压缩机模型详解图,图 4.13 泵模型详解图和图 4.14 涡轮模型详解图：


压缩机页面

文本信息模态压缩机模型准确率验证图



准确率达到97.35%

音频信息模态压缩机模型准确率验证图




准确率达到87.96%

[返回主页面](#)

图 4.12 压缩机模型详解图


泵页面

文本信息模态泵模型准确率验证图



准确率达到95.65%

音频信息模态泵模型准确率验证图




准确率达到90.97%

[返回主页面](#)

图 4.13 泵模型详解图


涡轮页面

文本信息模态涡轮模型准确率验证图



准确率达到97.03%

音频信息模态涡轮模型准确率验证图



准确率达到92.48%

返回主页面

图 4.14 涡轮模型详解图

4.4 系统测试

4.4.1 系统测试的概念和目的

系统测试是软件测试流程中的关键阶段，它是在软件开发完成、集成测试之后进行的综合性测试活动。从概念上讲，系统测试是将已经集成好的软件系统，作为一个整体元素，与计算机硬件、外设、支持软件、人员、数据等其他系统元素结合在一起，在真实的或模拟的实际运行环境下，对计算机系统进行全面且严格的测试。它不仅仅关注软件本身，还着眼于软件与整个系统环境中其他元素的交互和协同工作情况。

系统测试的目的在于通过与系统的需求定义作比较，发现软件与系统定义不符合或与之矛盾的地方，以验证软件系统的功能和性能等是否满足需求规格说明书的要求。具体而言，一方面是确保系统具备所期望的功能，能够正确处理各种输入并产生预期的输出；另一方面是检验系统在不同环境和条件下的稳定性、可靠性、兼容性等非功能特性，保证系统在实际应用中能够持续、稳定地运行，为用户提供可靠的服务。系统测试是软件生命周期中的重要环节，对于保障软件质量、提高用户满意度起着关键作用。

4.4.2 系统功能测试

本系统测试的主要重点在系统的功能是否能实现，对系统的登录，登出和各个功能页跳转按钮进行点击测试，发现系统都可以正常运行。

对系统添加权限用户功能进行测试，在添加权限用户页添加新用户，登出系统，使用新添加的用户名和密码进行登录测试，发现系统可以正常登录，此功能正常。具体情况可看下图 4.15 权限用户添加功能测试图：

The image shows two side-by-side screenshots of a web application interface. The left screenshot is titled '工业设备监测系统' (Industrial Equipment Monitoring System) and '用户注册' (User Registration). It features a '用户名' (Username) field with the value 'lucy' and a '密码' (Password) field with the value '999999'. Below these fields is a blue button labeled '确定添加用户' (Confirm Add User). The right screenshot is titled '工业设备故障检测系统' (Industrial Equipment Fault Detection System) and '设备在线' (Device Online). It features a '用户名' (Username) field with the value 'lucy' and a '密码' (Password) field with the value '999999'. Below these fields is a blue button labeled '登录系统' (Login System). Both screenshots show a green status indicator above the input fields.

图 4.15 权限用户添加功能测试图

对故障检测页的故障功能进行检测,输入不同的数据,用结果页的结果和应该得到的结果相对比,发现都吻合。输入数据有以下几种不同的输入方法,以一个机械部位为例。

(1) 音频信息正常,文本信息正常,得到机械为故障,对应图 4.16; (2) 音频信息正常,文本信息故障,得到机械为故障,对应图 4.17; (3) 音频信息故障,文本信息正常,得到机械为故障,对应图 4.18; (4) 音频信息故障,文本信息故障,得到机械为故障,对应图 4.19。测试结果如下所示:




图 4.16 情况 1 故障检测功能图



图 4.17 情况 2 故障检测功能图




图 4.18 情况 3 故障检测功能图




图 4.19 情况 4 故障检测功能图

由上述这些图可以得知，对应数据的测试都符合预测，同时次页面的波形图也可以正常生成。

4.4.3 系统测试结果

通过对系统现有的各个识别模块进行测试后发现现有的系统已对完成了对各个功能需求的实现，并且系统没有发现巨大漏洞。系统可以确保用户良好的使用体验。

4.5 本章小结

本章详细讲解了工业设备故障检测系统的可视化页面的构建思路和具体实现的方法。分析了 `django` 项目是如何进行 `html` 前端可视化和 `mysql` 数据库连接的。详细讲述了系统各个页面是如何实现的。使整个系统可以正常运行。完成了多模态数据结合判断工业设备是否故障的功能，此功能是通过使用余弦相似度算法来实现的。完成了对系统的测试，确保了系统没有故障，为用户提供了良好的使用体验。

结 论

本文主要研究了工业设备故障检测系统，该系统通过训练三种不同类别的模型，分别为文本信息模态判断机械部位是否故障模型，音频信息模态判断机械部位是否故障模型，音频信息模态判断是哪个机械部位模型。运用余弦相似度来完成两种不同信息模态模型结果与机械设备现实情况的对应，让其能实现通过多模态数据（如温度，压力等和音频）综合来判断机械是否故障，能够提供更为全面的设备健康评估，从而提高故障检测的准确性和可靠性。分享了工业设备故障检测系统可视化的思路和每个页面的实现方法，讲述了神经网络模型在 `django` 项目中该如何调用和调用前如何配置环境。

本文主要的工作内容如下：

（1）分享了本项目中核心技术有哪些，这些核心技术的优点和特性。为何会选择在工业设备故障检测系统中使用这些技术。

（2）完成文本信息模态模型的训练，分析了为何选择前馈神经网络模型来完成文本信息模态模型的训练。分享了如何完成前馈神经网络模型训练所需要的数据集的搜集与分析了如何对数据集进行清洗，将数据转化成前馈神经网络模型所需的格式。讲解了前馈神经网络模型的优点和此工业设备故障检测系统中前馈神经网络模型是如何进行训练。分享了前馈神经网络模型训练后对数据的准确率。

（3）完成两类音频信息模态模型（判断是哪个机械部位模型和判断机械部位是否故障模型）的训练，分析了为何选择循环神经网络模型来完成文本信息模态模型的训练。分享了如何完成循环神经网络模型训练所需要的数据集的搜集与分析了如何对数据集进行清洗。为什么会选择使用对音频数据做 `MCFFT` 处理，以及如何对音频数据做 `MCFFT` 处理。如何将做 `MCFFT` 处理过的数据转化成循环神经网络模型所需的格式。讲解了为何选择使用双向 `LSTM` 来训练循环神经网络模型。讲解了工业设备故障检测系统中循环神经网络模型是如何进行训练。分享了两类循环神经网络模型中各自的准确率。

（4）完成了工业设备故障检测系统的可视化，对系统进行的需求分析，根据每个需求设计了对应的可视化页面。使用 `django` 框架完成的每个页面的编写，使整个系统可以完美运行。完成了多模态数据结合判断工业设备是否故障功能，通过使用余弦相似度来实现此功能。完成了对系统的测试，确保了系统没有故障，为用户提供了良好的使用体验

参考文献

- [1] Sun J , Yan C , Wen J .Intelligent Bearing Fault Diagnosis Method Combining Compressed Data Acquisition and Deep Learning[J].IEEE Transactions on Instrumentation and Measurement, 2017, 67(99):185-195.DOI:10.1109/TIM.2017.2759418.
- [2] Liu Q , Wang H P .A case study on multisensor data fusion for imbalance diagnosis of rotating machinery[J].Ai Edam, 2001, 15(3):203-210.DOI:10.1017/S0890060401153011.
- [3] Li H , Huang J ,Huang J.Chai S.Zhao L.Xia Y.Deep Multimodal Learning and Fusion Based Intelligent Fault Diagnosis Approach[J].journal of beijing institute of technology (english edition), 2021, 30(2):172-185.DOI:10.15918/j.jbit1004-0579.2021.017.
- [4] Lv D , Wang H , Che C .Fault diagnosis of rolling bearing based on multimodal data fusion and deep belief network:[J].Proceedings of the Institution of Mechanical Engineers, Part C: Journal of Mechanical Engineering Science, 2021, 235(22):6577-6585.DOI:10.1177/09544062211008464.
- [5] Liu Y .Construction of Knowledge Graph for Marine Diesel Engine Faults Based on Deep Learning Methods[J].Journal of Marine Science and Engineering, 2025, 13.DOI:10.3390/jmse13040693.
- [6] Oman P , Krings A , Conte d L D ,et al.Analyzing the security and survivability of real-time control systems[C]//Information Assurance Workshop.IEEE, 2004.DOI:10.1109/IAW.2004.1437837.
- [7] Wang T , Qi G , Wu T .KGroot: Enhancing Root Cause Analysis through Knowledge Graphs and Graph Convolutional Neural Networks[J]. 2024.
- [8] Chen J , Qian J , Zhang X ,et al.Root-KGD: A Novel Framework for Root Cause Diagnosis Based on Knowledge Graph and Industrial Data[J]. 2024.
- [9] Djeziri M A , Merzouki R , Bouamama B O ,et al.Robust Fault Diagnosis by Using Bond Graph Approach[J].IEEE/ASME Transactions on Mechatronics, 2007, 12(6):599-611.DOI:10.1109/TMECH.2007.912746.
- [10]Zhang, S., Zhang, S., Wang, B., & Habetler, T. G. (2019). Machine Learning and Deep Learning Algorithms for Bearing Fault Diagnostics — A Comprehensive Review. arXiv preprint arXiv:1901.08247.
- [11] Alshorman O , Alkahatni F , Masadeh M ,et al.Sounds and acoustic emission-based early fault diagnosis of induction motor: A review study:[J].Advances in Mechanical Engineering, 2021(2).DOI:10.1177/1687814021996915.
- [12] 拓扑优化结构再设计中的神经网络求解方法[J]. 陈高勇;何彬;赵刚.机械设计与制造,2023(09).

- [13] 边巴拉姆,白天可,殷锐,等.深度学习算法在山南市雅桑站流量模拟中的应用研究[J/OL].水电能源科学,2025,(07):11-15[2025-05-23].
- [14] 王凤,陈天浩,盛忠起.拓扑优化结构的卷积神经网络求解方法[J/OL].机械设计与制造,1-5[2025-05-23].
- [15] 徐五一,杨岗,卫昱乾,等.基于机器学习的旋转机械故障识别算法的输入特征综述[J/OL].西华大学学报(自然科学版),1-16[2025-05-23].
- [16] 李晓佳.基于改进 CNN 与 RNN 的物联网入侵检测模型[D].哈尔滨师范大学,2023.DOI:10.27064/d.cnki.ghasu.2023.001366.
- [17] 罗晓青.基于频谱的柴油发电机振动故障诊断方法[J].内燃机与配件,2025,(06):83-85.DOI:10.19475/j.cnki.issn1674-957x.2025.06.024.
- [18] 叶万兴.基于并行卷积神经网络的风机叶片开裂故障预测[D].广西大学,2024.DOI:10.27034/d.cnki.ggxju.2024.001342.
- [19] 刘川,马玉娟,范剑超.基于小样本生成对抗网络的光学遥感影像溢油语义分割[J].海洋环境科学,2025,44(01):107-115.DOI:10.13634/j.cnki.mes.2025.01.004.
- [20] 王子斌.基于迁移学习的跨领域数据分类方法研究[J].大数据时代,2025,(02):39-43.
- [21] Wu D , Pigou L , Kindermans P J ,et al.Deep Dynamic Neural Networks for Multimodal Gesture Segmentation and Recognition[J].IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(8):1-1.DOI:10.1109/TPAMI.2016.2537340.
- [22] Ma Y , Zheng Y , Zhang W ,et al.Optimization of semi-supervised generative adversarial network models: a survey[J].International Journal of Intelligent Computing and Cybernetics, 2024(4):17.
- [23] Chen T , Xiang Y , Wang X .IFD-BiC: a class-incremental continual learning method for diesel engine fault diagnosis[J].IOP Publishing Ltd, 2025.DOI:10.1088/2631-8695/adb19d.
- [24] He M , He D .Deep Learning Based Approach for Bearing Fault Diagnosis[J].IEEE Transactions on Industry Applications, 2017, 53(3):3057-3065.DOI:10.1109/TIA.2017.2661250.
- [25] Chen X , Li Q , Cai H ,et al.Heterogeneity-aware Personalized Federated Learning via Adaptive Dual-Agent Reinforcement Learning[J]. 2025.
- [26] Maschler B , Knodel T , Weyrich M .Towards Deep Industrial Transfer Learning for Anomaly Detection on Time Series Data[J]. 2021.DOI:10.48550/arXiv.2106.04920.
- [27] Shen J , Yang S , Zhao C ,et al.FedLED: Label-Free Equipment Fault Diagnosis With Vertical Federated Transfer Learning[J].IEEE Transactions on Instrumentation and Measurement, 2024:73.DOI:10.1109/TIM.2024.3352702.

- [28] Funa,Zhou,Po,et al.A Multimodal Feature Fusion-Based Deep Learning Method for Online Fault Diagnosis of Rotating Machinery.[J].Sensors, 2018.DOI:10.3390/s18103521.
- [29] Malathi S , Michael W , Frazier S ,et al.Comparing problem-based learning with case-based learning: effects of a major curricular shift at two institutions[J].Academic medicine : journal of the Association of American Medical Colleges, 2015, 2007 年 82 卷 1 期:74-82 页.DOI:10.1097/01.ACM.0000249963.93776.aa.
- [30] Ding X , He Q , Luo N .A fusion feature and its improvement based on locality preserving projections for rolling element bearing fault classification[J].Journal of Sound & Vibration, 2015, 335:367-383.DOI:10.1016/j.jsv.2014.09.026.
- [31] 卓文海,刘庆杰,徐璐,等.基于MFCC-CNN的轨道交通车致二次结构噪声信号识别[J].铁道建筑,2025,65(04):137-142.
- [32] Wu Y, Liu F, Wan L, et al. Intelligent fault diagnostic model for industrial equipment based on multimodal knowledge graph[J]. IEEE Sensors Journal, 2023.

攻读学士学位期间取得的学术成果

致 谢

感谢我的毕设指导教师，从毕业设计开题答辩开始一直到毕业论文的完成这期间，每次提出无论是技术上的难题还是论文撰写方面的问题，老师总是会耐心的解答，同时老师严谨认真的态度也给了我很大的帮助。感谢学长，在实验室完成毕业设计及撰写论文期间，学长会定期检查相关进度并对其中存在的问题提出改正意见，正因为有老师和学长的帮助，才使得我能够按时完成毕业设计的编程任务以及论文的撰写工作。

感谢实验室的另外一位学长，学长在我面对深度学习方面的困难是，向我推荐正确合适的论文，并对我设计的系统以及研究的算法提出了一些宝贵的意见。同时还要感谢在实验室中一起做毕设的同学们，在我遇到问题时，热情的给予我帮助，在论文的撰写阶段，互相及时指出论文中的不足并且提出修改建议，这也对我论文的完善起到了至关重要的作用。

感谢哈尔滨工程大学，她浓厚的学习氛围和丰富的课余生活让我度过了最美好的一段时光，感谢计算机科学与技术学院的各位老师和领导对我的培养，正是因为有你们，我才能够在这四年期间成长为一名合格的大学生。

最后感谢我的父母和我的朋友们，你们是我生命中永远的依靠，你们的鼓励与支持是让我勇往直前的动力。