

学 号：2021066110

密 级：_____

哈尔滨工程大学本科生毕业论文

高质量多模态数据集构建研究 with 实现

学 院 名 称：计算机学院

专 业 名 称：信息安全

学 生 姓 名：陈修宇

指 导 教 师：吕继光副教授

哈尔滨工程大学

2025年5月

高质量多模态数据集构建研究与实现

陈修宇

哈尔滨工程大学

学 号: 2021066110

密 级: _____

高质量多模态数据集构建研究 with 实现

Research and Implementation of High-Quality Multimodal Dataset Construction

学 生 姓 名: 陈修宇

所 在 学 院: 计算机学院

所 在 专 业: 信息安全

指 导 教 师: 吕继光

职 称: 副教授

所 在 单 位: 哈尔滨工程大学

论文提交日期: 2025年6月

论文答辩日期: 2025年6月

学位授予单位: 哈尔滨工程大学

哈尔滨工程大学

学位论文原创性声明

本人郑重声明：本论文的所有工作，是在导师的指导下，由作者本人独立完成的。有关观点、方法、数据和文献的引用已在文中指出，并与参考文献相对应。除文中已注明引用的内容外，本论文不包含任何其他个人或集体已经公开发表的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

作者（签字）：陈修宇

日期：2025年6月12日

哈尔滨工程大学

学位论文授权使用声明

本人完全了解学校保护知识产权的有关规定，即在校攻读学位期间论文工作的知识产权属于哈尔滨工程大学。哈尔滨工程大学有权保留并向国家有关部门或机构送交论文的复印件。本人允许哈尔滨工程大学将论文的部分或全部内容编入有关数据库进行检索，可采用影印、缩印或扫描等复制手段保存和汇编本学位论文，可以公布论文的全部内容。同时本人保证毕业后结合学位论文研究课题再撰写的论文一律注明作者第一署名单位为哈尔滨工程大学。涉密学位论文待解密后适用本声明。

本论文（☐在授予学位后即可 ☐在授予学位 12 个月后 ☐解密后）由哈尔滨工程大学送交有关部门进行保存、汇编等。

作者（签字）：陈修宇

导师（签字）：吕建尧

日期：2025年6月12日

2025年6月12日

摘 要

随着人工智能与深度学习技术的快速发展，“图像-文本”多模态学习通过跨模态融合图像和文本两种形式的数据，很好的提升了模型的理解力、泛化能力和实用性。工业场景特别是缺陷检测、质量控制和自动化生产等应用，由于其对数据质量和模型精准度的高要求，十分依赖高质量的“图像-文本”多模态数据集。

本文以工业检测数据集MVTec Anomaly Detection (MVTec AD)为实验基础，对目前主流的三种自动化标注方法进行工业场景适配调整，提出三种新方法，分别是基于缺陷先验知识的模板增强标注方法、基于多模态预训练模型的自监督匹配标注方法和基于生成对抗网络的图像-文本协同标注方法。这三种方法通过不同的技术路线，互补适配工业场景复杂多样的需求。

之后通过实验在MVTec AD数据集的基础上使用三种新方法进行标注构建，得到三套不同的“图像-文本”数据集，并以COCO 2017数据集的1万对人工标注的子集为基准，评估三套“图像-文本”数据集的质量，并通过图像描述生成和图像-文本检索两种任务验证其性能。

实验结果显示，模板增强方法标注的数据集的标注一致性最优，在图像-文本检索任务上表现最好，最适合这种需要高一致性的任务；自监督匹配方法标注的数据集的文本语义十分丰富、泛化能力强，在图像描述生成任务里表现最好；图像-文本协同方法标注的数据集兼顾文本多样性与标注精准度，虽然在两种任务里的表现都不是最优，但综合起来最是均衡。三种方法都大幅降低了数据集标注对人工的需求，展现出了显著的工业应用潜力。

关键词：多模态学习；图像-文本数据集；工业缺陷检测；语义一致性

ABSTRACT

With the rapid advancement of artificial intelligence and deep learning, "image-text" multimodal learning has significantly enhanced model comprehension, generalization, and practicality by integrating image and text data across modalities. Industrial applications, particularly in defect detection, quality control, and automated production, rely heavily on high-quality "image-text" multimodal datasets due to their stringent requirements for data quality and model accuracy.

This Thesis builds on the MVTec Anomaly Detection (MVTec AD) dataset as the experimental foundation and adapts three mainstream automated annotation methods for industrial scenarios, proposing three novel approaches: a template-enhanced annotation method based on defect prior knowledge, a self-supervised matching annotation method leveraging multimodal pretrained models, and an image-text collaborative annotation method based on generative adversarial networks. These methods, through distinct technical pathways, complementarily address the complex and diverse needs of industrial scenarios.

Experiments were conducted to construct three distinct "image-text" datasets using the proposed methods on the MVTec AD dataset. The quality of these datasets was evaluated against a benchmark of 10,000 manually annotated image-text pairs from the COCO 2017 dataset, with performance assessed through image captioning and image-text retrieval tasks.

Results demonstrate that the template-enhanced method achieves the highest annotation consistency, excelling in image-text retrieval tasks and proving ideal for applications requiring high consistency. The self-supervised matching method produces datasets with rich textual semantics and strong generalization, performing best in image captioning tasks. The image-text collaborative method balances textual diversity and annotation accuracy, delivering solid but not top performance in both tasks, making it the most balanced overall. All three methods significantly reduce reliance on manual annotation, showcasing substantial potential for industrial applications.

Keywords: Multimodal Learning; Image-Text Dataset; Industrial Defect Detection; Semantic Consistency

目 录

第1章 绪论.....	1
1.1 研究背景.....	1
1.2 国内外研究现状.....	2
1.3 研究目标和内容.....	3
1.4 论文结构.....	4
第2章 相关技术概要.....	5
2.1 文本生成与改写技术.....	5
2.1.1 BLIP 模型.....	5
2.1.2 LLaVA 模型.....	7
2.2 图像-文本匹配与文本去重技术.....	8
2.2.1 CLIP 模型.....	8
2.2.2 BERT 模型.....	9
2.3 工业特征提取与多样性增强技术.....	11
2.3.1 PatchCore 模型.....	11
2.3.2 K-means 聚类.....	12
2.3.3 生成对抗网络（GAN）.....	13
2.4 本章小节.....	14
第3章 高质量多模态数据集构建方法.....	15
3.1 基于缺陷先验知识的模板增强标注方法.....	15
3.1.1 模板增强标注方法概述.....	15
3.1.2 模板增强标注流程步骤.....	16
3.2 基于多模态预训练模型的自监督匹配标注方法.....	17
3.2.1 自监督匹配标注方法概述.....	17
3.2.2 自监督匹配标注流程步骤.....	19
3.3 基于生成对抗网络的图像-文本协同标注方法.....	20
3.3.1 图像-文本协同标注方法概述.....	20
3.3.2 图像-文本协同标注流程步骤.....	21
3.4 本章小结.....	22

第4章 评估与实验	23
4.1 实验设置	23
4.1.1 实验环境与数据集	23
4.1.2 模型参数配置	23
4.1.3 评估指标	24
4.2 数据集构建	25
4.2.1 数据集 1: 模板增强标注	25
4.2.2 数据集 2: 自监督匹配标注	27
4.2.3 数据集 3: GAN 协同标注	29
4.2.4 数据集 4: COCO 子集	31
4.3 数据集质量评估	31
4.4 下游任务验证	33
4.4.1 任务设置与流程	33
4.4.2 任务结果	35
4.5 方法特性总结	36
4.5.1 任务中质量指标的影响分析	36
4.5.2 方法优劣与倾向性分析	37
4.6 本章小节	38
结论	39
参考文献	40
攻读学士学位期间发表的论文和取得的科研成果	43
致 谢	44

第1章 绪论

1.1 研究背景

随着深度学习技术的快速发展，单模态任务如图像分类、语音识别、自然语言处理等均取得显著突破。然而，为了使计算机更高效地理解和认知世界，多模态学习逐渐为学者们所重视。多模态学习融合图像、文本、语音、视频等多种不同模态的数据，以信息互补的方式，显著增强模型的语义理解和决策准确性。

“图像-文本”多模态学习是多模态学习中最基础的几个组合之一。凭借图像在捕捉丰富视觉特征方面的天然优势与文本在表达抽象概念、复杂上下文以及细致细节方面的卓越能力，“图像-文本”多模态学习在信息表达上展现出高度的互补性。图像和文本的结合能够让模型以更加全面且深入的方式理解和表示复杂信息。而得益于互联网上随处可见的大量“图像-文本”成对数据——无论是社交媒体上的图片配文，还是网页中的图文并茂内容，此类多模态模型的开发与性能优化都得到了极大推进。通过将两种模态映射到统一语义空间，实现跨模态的知识共享，“图像-文本”多模态模型在用文本描述指导图像生成，或用图像辅助文本分类一类的零样本学习、迁移学习等场景中的表现十分出色。

“图像-文本”多模态学习在工业场景中也日益展现出独特的价值。工业环境中的“图像-文本”多模态模型可以通过分析设备磨损的图像和维护记录的文本，精准识别潜在故障并提出维修建议，减少停机时间。制造过程中，“图像-文本”多模态模型通过图像捕捉产品的外观特征，文本提供标准规范或缺陷描述，通过联合学习能更准确地判断产品是否符合质量要求，检测产品缺陷。传统的工业操作依赖经验丰富的工人，而“图像-文本”多模态模型可以通过学习历史数据和专家知识，辅助新手工人或自动化系统完成复杂任务，减少培训时间和人工成本。

然而，想要构建高质量的“图像-文本”多模态数据集以满足高性能多模态模型的训练的需求，还存在以下4个问题：

(1) 语义一致性不足是首先需要解决的一项。图像与文本需实现高度的语义匹配，图像内容要能够精准反映文本描述的细节，而文本描述也需要全面表达图像的视觉特征。而如果文本描述遗漏关键缺陷或者文本描述超出图像内容，都可能导致模型学习到错误的语义模式，推理能力降低。在工业场景中，缺陷图像的细微差异，如划痕的深浅，都需与文本描述精确对应。

(2) 人工标注成本的高昂很大程度上限制了数据集的规模。传统的人工标注依赖领域专家的专业知识，耗时耗力且成本高昂。而且人工标注的数据集还容易受到个人主观因素的影响而导致语义一致性下降，难以满足大规模的数据需求。

(3) 描述是否具备多样性决定了模型的泛化能力。高质量的数据集描述需要涵盖丰富的表达形式和场景细节以支持模型在动态环境中的适应性。在工业场景中，图像常常涉及多种设备、环境和视角，文本需包含多样化的专业术语和语言风格，单一描述形式会限制模型的语义理解能力。

(4) 工业场景的领域特殊性对数据集提出了更高要求。相较于通用场景，如COCO数据集的日常图像^[1]，工业数据集需体现缺陷类型、设备特性和工艺背景等专业知识，通用标注方法难以满足其精细化需求，导致领域相关性不足。

针对上述挑战，本文以MVTec AD数据集为实验基础，探索自动化标注技术的可行性，致力于构建高质量的“图像-文本”多模态数据集。通过研究高效、低成本的标注方法，解决语义一致性、标注成本和描述多样性的难题，旨在为工业场景的多模态学习任务提供优质数据支持，进而推动智能工业应用的深入发展。研究成果不仅能够为学术界提供多模态数据集构建的新思路，还能够为工业界的智能化升级贡献实用价值。

1.2 国内外研究现状

“图像-文本”多模态学习通过融合视觉与语义信息，构建跨模态表示，显著提升模型的理解和推理能力。国外研究在技术创新上处于前沿。OpenAI的CLIP模型^[2]通过400M图像-文本对的对比学习，实现了零样本跨模态匹配，广泛应用于图像-文本检索和视觉问答。Meta AI的BLIP模型^[3]结合生成与检索任务，通过多任务预训练优化语义理解，适用于图像描述生成。Google的Flamingo模型^[4]进一步整合视觉和语言模型，支持开放域问答，展现了多模态交互的潜力。国内研究紧跟国际步伐，取得显著进展。清华大学开发的WenLan模型针对中文场景优化跨模态表示^[5]，在图像描述生成和文化相关任务中表现优异。阿里巴巴的M6模型^[6]通过大规模中文数据预训练，增强了电子商务场景的跨模态检索能力。近期，百度提出UniVL模型^[7]，结合视频和文本数据，提升了动态场景的语义理解。

多模态数据集的构建是多模态学习的核心基础，其质量直接影响模型的训练效能与泛化能力。国外研究中，微软研发的COCO数据集^[1]通过精细的人工标注，提供了数十万高质量图像-文本对，广泛应用于预训练和下游任务评估。斯坦福大学的Visual Genome数据集^[8]以丰富的语义细节著称，支持复杂场景的深层语义理解。针对工业场景，MVTec

公司推出的MVTec AD数据集^[10]包含约5000张缺陷图像，专注于工业异常检测。国内研究也在多模态数据集构建方面取得显著进展，中国科学院自动化研究所提出ChinaOpen数据集^[11]，整合中文互联网内容，面向开放世界多模态学习，支持跨模态对齐与推理任务，提升模型在中文语境下的泛化能力。武汉大学发布WuDaoMM数据集^[12]，覆盖教育、电商等垂直领域，为中文多模态预训练提供开源基准。华为联合学术界推出Wukong数据集^[14]，注重高质量图文对，推动中文CLIP类模型性能超越国际同类模型。

而为应对人工标注的高成本，自动化标注技术逐渐成为研究热点。Ratner等^[15]提出的Snorkel框架通过弱监督学习，利用规则和启发式函数快速生成训练标签，显著降低了标注成本，适用于大规模“图像-文本”数据集构建，尤其在初始标注阶段展现高效性。Lee^[16]提出的伪标签方法采用半监督学习，通过模型自身预测生成伪标签，进一步减少对人工标签的依赖，特别适合小规模数据集的自动化标注，为多模态任务提供了灵活的解决方案。Goodfellow等^[18]提出的生成对抗网络（GAN）通过生成器与判别器的对抗训练，显著增强了文本描述的多样性，为工业场景的动态表达需求（如缺陷类型和场景变化）提供了可能。

多模态学习在工业场景的应用日益广泛，尤其在缺陷检测、设备监控和异常分析中展现出独特价值。研究表明，融合图像、文本和传感器数据能显著提升系统感知能力。Peng等^[19]提出基于一种多模态知识图谱的滚动轴承故障诊断方法，整合轴承图像与故障描述，通过图神经网络优化语义一致性。陶显等^[20]综述了深度学习在表面缺陷检测中的应用，强调图像与文本融合对精细化分类的潜力，但指出标注成本高昂的限制。Qu等^[21]开发MFGAN模型，结合注意力自编码器和GAN，融合图像与传感器数据，提升生产线异常检测精度。Cheng等^[24]通过单模态与跨模态融合，优化工业异常检测的鲁棒性，特别针对复杂生产线场景。Wang等^{错误!未找到引用源。}提出多模态回归模型，融合无人机图像与状态描述，实现高效异常检测。

1.3 研究目标和内容

针对多模态学习中“图像-文本”数据集构建的挑战，尤其是工业场景下语义一致性不足、标注成本高昂、描述多样性有限及领域特殊性要求高的难题，本文的研究目标在于开发高效、低成本的自动化标注技术和构建高质量的多模态数据集。具体而言，本文以MVTec AD数据集为实验基础，提出三种创新的自动化标注方法，分别是基于缺陷先验知识的模板增强标注方法、基于多模态预训练模型的自监督匹配标注方法以及基于生成对抗网络的图像-文本协同标注方法，力求在语义一致性、标注质量和描述多样性上取

得突破，同时满足工业场景的领域相关性需求。

研究内容包括以下几个方面：

- (1) 基于MVTec AD数据集，设计并实现三种自动化标注方法，完成三套各含1万对“图像-文本”数据的数据集的构建。
- (2) 通过多维度指标评估数据集的语义一致性、标注质量和描述多样性，同时与COCO 2017的1万对人工标注子集进行对照分析。
- (3) 在图像描述生成和图像-文本检索任务中测试构建出的三个数据集的性能，深入探讨数据集质量对下游任务效果的影响。
- (4) 分析三种自动标注方法的优劣并提出优化建议，为工业场景的多模态学习提供理论与实践参考。

1.4 论文结构

本文系统性的阐述了基于MVTec AD数据集的三种“图像-文本”多模态数据集的构建过程、质量评估及在工业场景中的应用效果，旨在为多模态学习和智能工业应用提供坚实的数据支持。

论文共分为五章节，结构安排如下：

第一章为引言，主要介绍多模态学习的研究意义和国内外研究现状，基于目前的研究难题明确研究目标和内容。

第二章介绍主要的相关技术，包括用于文本生成的BLIP模型和用于图像-文本匹配的CLIP模型、缺陷检测的PatchCore模型以及K-means聚类、生成对抗网络等相关技术。

第三章则阐述了三种自动化标注方法的实现过程，重点解决语义一致性、标注质量和描述多样性问题，并通过CLIP模型验证语义匹配精度。

第四章介绍实验设计与结果分析，展示基于MVTec AD数据集构建的三套各含1万对“图像-文本”数据集的实验结果。通过多维度指标评估数据集的语义一致性、标注质量和描述多样性的同时与COCO 2017人工标注子集进行对照。

最后总结本文的研究成果，概括三种方法在工业场景中的贡献与局限性，并展望未来的研究方向。

第 2 章 相关技术概要

本章旨在系统性地介绍构建高质量“图像-文本”多模态数据集所需的核心技术，为后续的自动化标注方法设计和实验验证奠定理论与技术基础。主要包括用于生成和改写文本描述的BLIP和LLaVA模型；用于图像-文本匹配与文本去重CLIP和BERT模型和用于工业缺陷特征提取、数据多样性增强和对抗优化生成的PatchCore、K-means聚类及生成对抗网络。

2.1 文本生成与改写技术

2.1.1 BLIP模型

BLIP (Bootstrapping Language-Image Pre-training) 模型作为一种视觉-语言预训练模型，在多模态学习领域表现卓越，能够高效生成语义相关的文本描述，特别适合自动化标注场景。说到底，构建高质量的“图像-文本”数据集离不开精准的描述生成，而BLIP的混合架构和创新训练方法，为工业场景的缺陷检测任务提供了强有力的支持。本文利用BLIP作为核心工具，生成MVTec ADe数据集的缺陷描述，支持第三章提出的三种自动化标注策略（模板增强、自监督匹配、GAN协同）。

BLIP采用了一种灵活的编码器-解码器混合架构，称为MED (Multimodal mixture of Encoder-Decoder)，能够无缝切换多种工作模式以应对图像-文本任务的需求。如图2.1，该架构包含三个核心模块：图像编码器、文本编码器和跨模态交互模块。

(1) 图像编码器基于Vision Transformer (ViT-L/14)，包含24层Transformer模块，隐藏层尺寸1024，配备16个注意力头，将输入图像分割为 14×14 块，生成特征序列： $\mathbf{v}_I = \{v_1, v_2, \dots, v_n\}$ ，其中全局特征 $v_{[CLS]}$ 表示整体语义。

(2) 文本编码器采用12层Transformer架构，隐藏层尺寸768，12个注意力头，词汇表大小49,408，生成文本特征序列 $\mathbf{v}_T = \{t_1, t_2, \dots, t_m\}$ 。

(3) 跨模态交互模块通过注意力机制融合图像和文本特征，生成统一表示，计算公式为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-1)$$

其中， Q (Query)来自文本特征， K (Key)和 V (Value)来自图像特征， d_k 为特征维度。跨

模态模块支持生成（自回归解码）和匹配（概率计算）任务。




图2.1 BLIP的预训练模型架构和目标

BLIP通过三种视觉-语言预训练目标学习图像与文本的语义关联，分别为图像-文本对比学习（ITC）、图像-文本匹配（ITM）和图像条件语言建模（ITG），在大规模数据集上联合优化，确保模型在生成和匹配任务中的出色表现。

(1) 图像-文本对比学习：通过对比学习对齐图像和文本的全局语义，最大化匹配对的相似度，最小化不匹配对的相似度。采用InfoNCE损失函数：

$$L_{ITC} = -\frac{1}{N} \sum_{i=1}^N \left[\log \frac{\exp(\cos(v_I^i, v_T^i)/\tau)}{\sum_{j=1}^N \exp(\cos(v_I^i, v_T^j)/\tau)} \right] \quad (2-2)$$

其中， v_I^i 和 v_T^i 为第 i 个匹配图像-文本对的嵌入， $\cos(\cdot)$ 为余弦相似度， $\tau = 0.07$ 为温度参数， N 为批次大小。ITC确保BLIP捕捉全局语义关联，如MVTec AD数据集中图像的整体缺陷特征。

(2) 图像-文本匹配：通过跨模态编码器判断图像-文本对是否匹配，采用二分类损失：

$$L_{ITM}(i) = -\frac{1}{N} \sum_{i=1}^N [y_i \log p_i + (1 - y_i) \log(1 - p_i)] \quad (2-3)$$

其中， $y_i \in \{0, 1\}$ 为匹配标签， p_i 为预测概率。ITM增强BLIP对局部特征的理解，如螺丝划痕的具体位置，适合工业场景的精准匹配。

(3) 图像条件语言建模（ITG）：基于图像特征生成文本描述，通过自回归解码预测词序列，损失为：

$$L_{ITG} = -\sum_{t=1}^T \log p(w_t | v_I, w_{1:t-1}) \quad (2-4)$$

其中, w_t 为第 t 个词, v_t 为图像特征。ITG使BLIP生成与MVTec AD数据集中图像高度相关的描述, 如“瓶子侧面有圆形凹陷”。

在本文中, BLIP的MED架构各部分功能如表2.1。

表2.1 MED各部分功能

模块	架构	参数	功能	论文应用
图像编码器	ViT-L/14	24层,1024维,16头	提取图像特征	MVTec 缺陷特征生成
文本编码器	Transformer	12层,768维,12头	提取文本特征	描述语义建模
跨模态模块	注意力机制	共享参数	融合生成/匹配	语义一致性优化

2.1.2 LLaVA模型

LLaVA (Large Language and Vision Assistant) 模型^[27]是一种高效的多模态语言-视觉模型, 专为图像-文本交互任务设计, 能够通过指令微调生成自然、语义相关的文本描述, 特别适合需要改写和优化描述的自动化标注场景。而工业场景的缺陷描述不仅要准确, 还要表达自然, LLaVA恰好能在这方面发挥大作用。本文利用LLaVA模型改写初始描述, 优化MVTec AD数据集的文本表达, 支持第三章提出的模板增强标注方法。

LLaVA模型采用了一种视觉-语言联合架构, 结合了CLIP的视觉编码器和LLaMA的语言模型, 通过跨模态投影层实现图像与文本的交互。如图2.2, 该架构包含三个核心模块: 视觉编码器、语言模型和跨模态投影层。




图2.2 LLaVA模型的架构

(1) 视觉编码器基于CLIP的ViT-L/336, 包含24层Transformer模块, 隐藏层尺寸1024, 配备16个注意力头, 将输入图像分割为 336×336 块, 生成特征序列 $v_t = \{v_1, v_2, \dots, v_n\}$ 。

(2) 语言模型采用LLaMA-13B, 包含40层Transformer模块, 隐藏层尺寸5120, 配备40个注意力头, 词汇表大小32,000, 支持高效的文本生成。

(3) 跨模态投影层通过线性映射将图像特征 v_t 对齐到语言模型的输入空间, 生成融合表示 $h_{I \rightarrow T}$, 公式为:

$$h_{I \rightarrow T} = W \cdot v_t + b \quad (2-5)$$

其中, W 和 b 为投影矩阵和偏置, $v_t \in \mathbb{R}^{1024}$, $h_{I \rightarrow T} \in \mathbb{R}^{5120}$ 。语言模型基于融合表示和文

本提示（如“自然语言改写”）进行自回归生成，预测词序列的概率：

$$p(w_t | h_{1 \rightarrow T}, w_{1:t-1}) = \text{softmax}(f(w_{1:t-1}, h_{1 \rightarrow T})) \quad (2-6)$$

其中， w_t 为第 t 个生成词， $f(\cdot)$ 为LLaMA的解码函数。

LLaVA的预训练分为两个阶段：视觉-语言对齐和指令微调，旨在提升模型的跨模态理解和生成能力。视觉-语言对齐阶段基于CLIP的预训练权重，利用400M图像-文本对进行对比学习，优化图像特征 v_I 和文本特征 v_T 的余弦相似度，确保跨模态表示的一致性。指令微调阶段使用LLaVA-13M数据集，通过监督微调（SFT）优化生成能力。微调目标为最大化生成序列的似然：

$$L_{SFT} = -\sum_{t=1}^T \log p(w_t | v_I, w_{1:t-1}, \text{prompt}) \quad (2-7)$$

其中， prompt 为指令提示（如“将描述改写为自然表达”）， w_t 为目标词， v_I 为图像特征。微调过程结合多样化指令（如“技术化描述”“自然表达”），提升模型对不同风格的适应性。在本文中，LLaVA的指令微调使其能够根据工业场景需求改写描述。

2.2 图像-文本匹配与文本去重技术

2.2.1 CLIP模型

CLIP（Contrastive Language-Image Pre-training）模型是一种视觉-语言预训练模型，通过对比学习在大规模图像-文本对数据上训练，将图像和文本映射到统一的特征空间，实现跨模态的语义对齐。工业场景的缺陷描述需要既准确又匹配图像内容，而CLIP能通过其高效的相似度计算，帮我们筛选出高质量的描述。本文利用CLIP模型进行语义一致性验证和质量评估，筛选高质量图像-文本对，量化数据集的匹配准确度。

CLIP模型采用双塔架构，包括图像编码器和文本编码器，通过投影层将图像和文本特征映射到统一的特征空间。如图2.3，该架构包含三个核心模块：图像编码器、文本编码器和投影层。

(1) 图像编码器基于Vision Transformer（ViT-B/32），包含12层Transformer模块，隐藏层尺寸768，配备12个注意力头，将输入图像分割为 32×32 块，生成特征序列 $v_I = \{v_1, v_2, \dots, v_n\}$ ，维度为512；

(2) 文本编码器同样采用Transformer架构，包含12层模块，隐藏层尺寸512，配备8个注意力头，生成文本特征序列 $v_T = \{t_1, t_2, \dots, t_m\}$ ，维度为512。

(3) 投影层通过线性映射和L2规范化将图像特征 v_I 和文本特征 v_T 对齐到统一空间，

计算余弦相似度：

$$S = \cos(v_I, v_T) = \frac{v_I \cdot v_T}{\|v_I\| \|v_T\|} \quad (2-8)$$




图2.3 CLIP模型架构

CLIP的核心在于通过对比学习实现跨模态语义对齐，训练数据为约4亿图像-文本对。对比学习的目标是最大化匹配图像-文本对的相似度，最小化不匹配对的相似度，采用InfoNCE损失函数公式(2-2)。

CLIP的对比学习机制为语义一致性验证提供了高精度支持，双塔架构为语义一致性验证提供了高效支持，CLIP各部分功能如表2.2。

表2.2 CLIP各部分功能

模块	架构	参数	功能	论文应用
图像编码器	ViT-B/32	12层,768维,12头	提取图像特征	MVTec缺陷特征提取
文本编码器	Transformer	12层,512维,8头	提取文本特征	描述语义建模
投影层	线性映射	768 维→512 维	跨模态对齐	语义一致性验证

2.2.2 BERT模型

BERT（Bidirectional Encoder Representations from Transformers）模型^[28]是一种基于Transformer架构的预训练语言模型，以其强大的双向语义建模能力，在自然语言处理任务中表现突出。工业场景的缺陷描述不仅要准确，还要避免重复，而BERT能帮我们在这方面把好关。本文利用BERT模型进行描述去重，确保MVTec AD数据集的文本表达独特性，支持第三章的自监督匹配和GAN协同方法。

BERT采用基于Transformer的编码器架构，具体为BERT-Base版本，包含12层Transformer模块，每层隐藏层尺寸为768，配备12个注意力头，总参数量约为110M。模型输入为文本序列（最大长度512），通过WordPiece分词和特殊标记（[CLS]和[SEP]）处

理后，生成词嵌入序列 $\mathbf{e} = \{e_{[CLS]}, e_1, \dots, e_n\}$ ，每一层Transformer通过多头自注意力机制捕捉词间语义关系，计算公式为(2-1)。

BERT的双向建模使其能够同时捕捉上下文信息，输出特征序列 $\mathbf{h} = \{h_{[CLS]}, h_1, \dots, h_n\}$ ，其中 $h_{[CLS]}$ 表示全局语义。BERT的整体预训练和微调流程如图2.4。




图2.4 BERT的整体预训练和微调流程

BERT的预训练通过两个任务实现：掩码语言模型（MLM）和下一句预测（NSP），在BookCorpus和英文Wikipedia数据（约3.3B词）上进行优化。MLM随机掩码15%的输入词（如将“划痕”替换为[MASK]），模型预测被掩码词，损失函数为：

$$L_{MLM} = - \sum_{i \in \text{masked}} \log p(w_i | w_{\setminus i}) \quad (2-9)$$

其中， w_i 为掩码词， $w_{\setminus i}$ 为上下文。NSP预测两句话是否连续（如“螺丝表面有划痕”是否接“位于顶部”），采用二分类损失：

$$L_{NSP} = -[y \log p + (1-y) \log(1-p)] \quad (2-10)$$

其中， $y \in \{0,1\}$ 为真实标签， p 为预测概率。预训练使BERT能够捕捉深层语义关系，适合工业描述的语义相似度计算。BERT参数与功能如表2.3。

表2.3 BERT参数与功能

模块	架构	参数	功能	论文应用
编码器	Transformer	12层,768维,12头	双向语义建模	描述语义特征提取
输出层	线性映射	768 维→分类概率	相似度计算	描述去重

2.3 工业特征提取与多样性增强技术

2.3.1 PatchCore模型

PatchCore (Patch-based Contrastive Representation) 模型^[29]是一种高效的工业缺陷检测技术，通过局部特征提取和异常评分，精准识别图像中的缺陷区域，特别适用于工业场景的精细化特征分析。工业场景的缺陷检测不仅要找准问题，还要细到划痕的形状、位置，这正是PatchCore的强项。本文利用PatchCore提取MVTec AD数据集的缺陷特征，支持第三章提出的模板增强标注方法，为后续描述生成提供领域相关的结构化信息。

PatchCore采用了一种基于局部特征的异常检测架构。如图2.5，结合预训练的ResNet-50网络和核密度估计KDE模块，实现了高效的缺陷特征提取。模型首先通过ResNet-50提取图像的深层特征，输入图像（尺寸 224×224 ）经过卷积和池化，生成多尺度特征图，提取中间层的特征，维度为2048。PatchCore将特征图分割为局部补丁patch，每个补丁对应一个特征向量 $\mathbf{f}_i \in \mathbb{R}^{2048}$ ，形成特征集合 $\mathbf{F} = \{\mathbf{f}_1, \mathbf{f}_2, \dots, \mathbf{f}_n\}$ 。为降低计算复杂度，PatchCore使用核采样(coreset sampling)策略，从 $\mathbf{F}$ 中选择代表性子集 $\mathbf{C} \subset \mathbf{F}$ ，通常规模为 $\mathbf{F}$ 的10%，保留核心特征。




图2.5 PatchCore模型架构

在异常检测阶段，PatchCore基于核密度估计计算每个补丁特征的异常分数。对于测试补丁特征 $\mathbf{f}_{\text{test}}$ ，异常分数 $s(\mathbf{f}_{\text{test}})$ 定义为与最近邻核心特征的距离：

$$s(\mathbf{f}_{\text{test}}) = \min_{\mathbf{c}_i \in \mathbf{C}} \|\mathbf{f}_{\text{test}} - \mathbf{c}_i\|_2 \quad (2-11)$$

其中， $\|\cdot\|_2$ 为欧氏距离， $\mathbf{C}$ 为训练集的核心特征子集。若 $s(\mathbf{f}_{\text{test}})$ 超过阈值（基于训练集异常分布确定），则判定该补丁为异常区域。PatchCore通过局部补丁分析，精准定位缺陷位置和类型。

PatchCore的核心在于利用预训练特征和异常评分实现无监督缺陷检测。模型基于ImageNet预训练的ResNet-50，无需额外标注即可提取通用特征，适配工业场景的少样本

检测需求。训练阶段，PatchCore从正常图像（无缺陷）中提取特征集合 F_{normal} ，通过核采样生成核心子集 C_{normal} 。测试阶段，对于MVTec数据集的缺陷图像，PatchCore提取测试补丁特征 f_{test} ，计算其与 C_{normal} 的最小距离 $s(f_{\text{test}})$ 。若距离超出阈值（基于正常样本的特征分布统计确定），则判定为缺陷区域。

异常检测的阈值通过训练集的异常分布确定，公式为：

$$\text{Threshold} = \mu_s + k \times \sigma_s \quad (2-12)$$

其中， μ_s 和 σ_s 分别为正常样本异常分数的均值和标准差， k 为调节系数（通常设为3）。PatchCore的无监督特性使其能够在MVTec AD数据集上高效运行，无需大规模标注即可识别缺陷特征。

2.3.2 K-means聚类

K-means聚类^[30]是一种经典的无监督学习算法，通过将数据点分配到若干簇中，增强数据的多样性和类别覆盖，特别适合工业场景中多模态数据集的构建需求。工业场景的缺陷图像种类繁多，单一描述很难覆盖所有情况，K-means聚类恰好能帮我们把把这些图像分门别类，为多样化描述生成打好基础。本文利用K-means聚类方法对MVTec AD数据集的图像特征进行分组，支持第三章自监督匹配方法的多样性增强。

K-means聚类算法通过最小化簇内方差，将数据点分配到 k 个簇中。其核心目标是优化以下损失函数：

$$J = \sum_{i=1}^k \sum_{C_i} \|x - \mu_i\|^2 \quad (2-13)$$

其中， C_i 表示第 i 个簇， μ_i 为簇中心， x 为数据点， $\|x - \mu_i\|^2$ 为数据点到簇中心的欧氏距离平方和。算法流程如下：首先，随机初始化 k 个簇中心；然后，迭代执行两个步骤：

- (1) 分配阶段，将每个数据点分配到距离最近的簇中心；
- (2) 更新阶段，重新计算每个簇的中心（均值），直至簇中心不再变化或达到最大迭代次数。

在本文中，K-means聚类的输入是MVTec AD数据集图像的视觉特征，基于ResNet-50提取（维度2048）。特征提取后，算法以 $k = 15$ 对应MVTec AD的15个物体类别进行聚类，确保每个簇覆盖不同的缺陷类型（如划痕、凹痕）和物体类别。K-means的参数与应用如表2.4。

表2.4 K-means的参数与应用

参数/功能	描述	论文应用
输入特征	ResNet-50,2048维	MVTec AD图像特征提取
簇数量 k	15（物体类别数）	类别均衡性保障
最大迭代次数	100次	高效聚类计算
应用目标	多样性增强、类别覆盖	描述生成多样性

2.3.3 生成对抗网络（GAN）

生成对抗网络（GAN, Generative Adversarial Network）是一种通过对抗训练生成高质量数据的深度学习框架^[32]，能够在图像-文本多模态任务中实现语义一致性与描述多样性的双重优化。工业场景的缺陷描述不仅要精准，还要表达丰富，GAN的对抗机制正好能在这方面大展身手。本文利用GAN构建高质量的“图像-文本”数据集，基于MVTec AD数据集，支持第三章提出的GAN协同标注方法。

GAN的核心架构包含两个主要模块：生成器（Generator）和判别器（Discriminator），通过对抗训练优化生成质量。在本文中，生成器基于BLIP模型，输入MVTec AD数据集图像特征 $\mathbf{v}_I$ 和噪声向 $\mathbf{z}$ ，生成文本描述 $\mathbf{T}_G$ ；判别器基于CLIP模型，输入图像-文本对 $(\mathbf{I}, \mathbf{T})$ ，输出匹配概率 $D(\mathbf{I}, \mathbf{T})$ 。生成器和判别器通过共享的跨模态特征空间交互，生成器目标是生成逼真的描述，判别器目标是区分真实描述（人工标注）与生成描述。训练过程中，生成器和判别器交替优化，形成对抗博弈。GAN的各项参数与功能如表2.5。

表2.5 BERT参数与功能

模块	架构	参数	功能	论文应用
生成器	BLIP	ViT-L/336,12层	生成描述	MVTec AD缺陷描述生成
判别器	CLIP	ViT-B/32,12层	评估匹配概率	语义一致性校验
多样性损失	余弦距离	$\cos(\mathbf{v}_{T_i}, \mathbf{v}_{T_j})$	增强描述多样性	多样化表达生成

在本文中，GAN的生成器利用BLIP的图像条件语言建模能力生成初始缺陷描述，判别器通过CLIP计算图像-文本对的余弦相似度，判断生成描述是否与图像匹配。若相似度低于阈值0.8，生成器调整策略（如修改提示），迭代优化（最多3次）。这种架构通过对抗训练，确保生成描述在语义一致性和多样性上满足工业场景需求。

GAN的训练目标是优化生成器和判别器的对抗损失，使生成描述尽可能接近真实分布。训练损失函数为：

$$\min_G \max_D \mathbb{E}_{(\mathbf{I}, \mathbf{T}) \sim p_{data}} [\log D(\mathbf{I}, \mathbf{T})] + \mathbb{E}_{\mathbf{I} \sim p_I, \mathbf{z} \sim p_z} [\log(1 - D(\mathbf{I}, G(\mathbf{I}, \mathbf{z})))] \quad (2-14)$$

其中, G 为生成器, D 为判别器, p_{data} 为真实数据分布, p_I 为图像分布, p_z 为噪声分布。生成器通过最小化判别器的误判概率生成逼真描述, 判别器通过最大化区分能力优化匹配精度。

为提升描述多样性, 本文在生成器中引入随机噪声 $\mathbf{z}$ (高斯分布, 均值0, 方差1), 并优化多样性损失, 最大化生成描述间的语义特征差异:

$$L_{\text{div}} = -\frac{1}{N} \sum_{i \neq j} \cos(\mathbf{v}_{T_i}, \mathbf{v}_{T_j}) \quad (2-15)$$

其中, $\mathbf{v}_{T_i}$ 和 $\mathbf{v}_{T_j}$ 为不同生成描述的特征 (由 CLIP 提取), N 为描述数量。多样性损失鼓励生成器输出风格迥异的描述, 例如“螺丝顶部有细长划痕”与“螺丝表面有一道线性擦伤”。

2.4 本章小节

本章系统总结了构建高质量“图像-文本”多模态数据集所需的核心技术, 为后续自动化标注和实验验证提供了坚实的理论与技术保障。BLIP和LLaVA模型通过多任务预训练和指令微调, 支持高效的文本描述生成与改写, CLIP和BERT模型分别实现精准的图像-文本匹配和文本去重, 保障语义一致性和描述独特性, PatchCore、K-means聚类和GAN技术分别通过缺陷特征提取、图像分组和对抗优化, 满足MVTec AD数据集的工业场景需求, 解决描述多样性和领域特殊性问题。这些技术共同应对了语义一致性不足、标注成本高昂等挑战, 为工业缺陷检测提供了高效支持。

第3章 高质量多模态数据集构建方法

针对语义一致性、标注质量和多样性对“图像-文本”多模态数据集构建的挑战，本章基于MVTec AD数据集，提出了三种高度自动化的标注方法，并通过后续评估指标和下游实验验证其效果，为工业场景下的多模态数据集构建提供创新性解决方案。

3.1 基于缺陷先验知识的模板增强标注方法

3.1.1 模板增强标注方法概述

在数据处理领域，先验知识是指任务执行前已知的、与任务相关的背景信息或规则，通常来源于数据标注或领域知识，能够为自动化处理提供结构化的语义基础。在MVTec AD数据集中，先验知识体现为15种物体类别的缺陷图像及其标注信息，包括明确的缺陷类型以及通过掩码照片提供的缺陷大小和位置信息。这些信息为多模态数据集构建提供了语义约束，降低了标注歧义，确保文本描述与图像内容的精准对应。如图3.1所示，缺陷图像与掩码的对应关系直观展示了先验知识。




图3.1 MVTec数据集先验知识示例：缺陷图像与掩码

基于缺陷先验知识的模板增强标注方法利用工业缺陷检测的先验信息（缺陷类型、位置、形状等），通过结构化模板生成初始文本描述，结合语言模型改写增强描述的自然性和多样性，并通过CLIP模型校验、迭代优化和人工审核确保语义一致性。其核心技术包括：PatchCore缺陷检测提取先验特征，结构化模板生成标准化描述，LLaVA语言模型改写提升表达多样性，CLIP校验结合最多三次迭代优化和人工审核保障质量。

相较于本文其他两种方法，本方法倾向于优先确保语义一致性和标注效率，适配工业场景的结构化需求。技术特点在于：

(1) 集成MVTec的工业先验知识，显著提升领域相关性和语义一致性，相较于通用生成模型（如BLIP）更适配工业场景；

(2) 采用迭代优化（最多三次）和人工审核机制，平衡标注效率与高质量输出。

本方法旨在为MVTec AD数据集构建高质量“图像-文本”多模态数据集，主要目标是确保语义一致性和标注效率，适度兼顾多样性，以适配工业场景的标准化需求。技术路线的确定基于MVTec AD的单一物体和明确缺陷特性，以及对现有技术的对比分析：

(1) PatchCore缺陷检测：MVTec AD图像以单一物体为中心，缺陷类型明确，PatchCore的异常评分机制精准提取缺陷特征（如划痕、顶部、线性），优于YOLO（缺乏缺陷特异性），为模板生成提供高质量先验，奠定语义一致性基础。

(2) 结构化模板生成：模板方法通过标准化描述高效生成文本，计算复杂度远低于BLIP直接生成，且可控性强，避免语义偏差，更适配MVTec AD的工业场景需求，确保标注效率和准确性。

(3) LLaVA改写：LLaVA基于多模态指令微调，支持多样化表达，其改写能力能够弥补模板的单一性，与模板生成协同提升多样性和语言流畅性，满足工业场景的多表达需求，相较于通用语言模型（如GPT-3），更适配图像-文本任务。

(4) CLIP校验与迭代优化：CLIP通过图像-文本特征匹配提供高精度校验（相似度阈值0.8），优于传统指标。迭代优化（最多3次）通过动态调整模板字段，将样本保留率提升至90%以上，相较于单次生成，鲁棒性更强，与LLaVA改写协同确保高质量输出。

技术组合逻辑基于以下考量：PatchCore提供精准先验，模板保证效率，LLaVA增强表达，CLIP和迭代优化保障质量。此组合充分发挥各技术优势，弥补单一技术的局限，优先确保高效生成高语义一致性的工业描述，区别于自监督匹配（平衡一致性和多样性）或GAN协同（探索复杂表达），满足MVTec AD的标准化需求。

3.1.2 模板增强标注流程步骤

方法的实现流程包括缺陷特征提取、模板化描述生成、多样性增强及语义一致性校验（即CLIP相似度）四个主要步骤，如图3.2所示，具体如下：

(1) 缺陷检测：利用预训练的缺陷检测模型PatchCore对MVTec图像进行分析，提取缺陷的类型、位置和形状等特征，为后续文本生成提供结构化的先验知识。例如，对于一张螺丝图像，检测结果可能为“划痕，位于顶部，形状为线性”。

(2) 模板化描述生成：基于缺陷检测结果，设计结构化模板生成初始文本描述。模板形式为“The surface of [object] has a [defect type] at [location], with a [shape] shape.”，通

过填充缺陷特征生成描述。为提高生成效率，可根据物体类别和缺陷复杂度扩展字段。




图3.2 基于缺陷先验知识的模板增强标注流程

(3) 多样性增强：为克服模板描述的单一性，利用预训练语言模型LLaVA对初始描述进行改写，生成更自然、丰富的文本表达。改写过程通过提示工程控制输出风格，确保多样性同时保留语义一致性。

(4) 为保证图像-文本对的质量，使用CLIP模型计算改写后描述与原始图像的匹配分数。CLIP通过提取图像特征 v_I 和文本特征 v_T ，计算余弦相似度：

$$S = \cos(v_I, v_T) = \frac{v_I \cdot v_T}{\|v_I\| \|v_T\|} \quad (2-16)$$

设定相似度阈值0.8。若匹配分数 $S \geq 0.8$ ，则保留该图像-文本对；否则，返回第二步模板化描述生成，调整模板参数并重新执行第三步多样性增强。该迭代过程最多进行3次。具体迭代机制如表3.1。

表3.1 模板增强标注迭代机制

步骤	输入	输出	条件
1.模板生成	缺陷特征	初始描述	动态调整模板字段
2.语言模型改写	初始描述	改写描述	提示工程控制风格
3.语义一致性校验	图像、改写描述	相似度分数	$S \geq 0.8$ 通过
4.迭代优化	低分描述	新模板与改写	最多3次迭代

3.2 基于多模态预训练模型的自监督匹配标注方法

3.2.1 自监督匹配标注方法概述

在多模态数据处理中，自监督学习通过利用数据本身的内在关联，如图像-文本对的

匹配关系，在无标注或少标注情况下优化模型性能，为数据集构建提供高效的语义对齐机制。MVTec AD数据集中的图像包含缺陷信息（如划痕、凹痕），但缺乏文本描述。人工标注成本高，传统生成模型缺乏领域适配性。

基于多模态预训练模型的自监督匹配标注方法利用多模态预训练模型BLIP生成初始文本描述，通过自监督学习优化图像-文本匹配质量，并结合图像聚类增强数据集的多样性，最终通过文本相似度校验和人工抽样确保标注质量。其核心技术包括：ResNet提取图像特征用于聚类，BLIP生成初始描述，CLIP自监督微调优化匹配，BERT过滤重复描述，以及人工抽样验证。相较于本文其他两种方法，本方法倾向于平衡语义一致性和多样性，以适配多样化的下游任务需求。

技术特点在于：(1) 通过自监督微调BLIP模型，适配MVTec的工业场景，提升领域相关性和语义一致性，相较于通用生成模型（如直接使用BLIP）更精准；(2) 采用图像聚类策略，确保数据集覆盖多种缺陷和物体类别，显著增强多样性。

本方法通过分析工业场景的多样化需求和现有技术局限，确定了由BLIP生成、CLIP自监督微调、ResNet特征聚类、BERT文本校验和人工抽样组成的技术路线。MVTec AD数据集的缺陷场景多样，要求数据集兼顾语义一致性和表达多样性，而纯BLIP生成缺乏领域适配，人工标注无法覆盖多样化场景。技术组合的确定过程如下：

(1) BLIP生成：BLIP的多模态预训练能力支持初始描述生成，相较于其他生成模型（如VLP，训练成本高），其图像-文本对齐能力更强，为后续优化提供高质量起点。

(2) CLIP自监督微调：CLIP的图像-文本匹配精度优于传统指标（如BLEU），自监督微调利用MVTec的无标注数据适配工业场景，相较于有监督微调（需标注数据），成本低且灵活。

(3) ResNet特征聚类：ResNet提取的视觉特征支持图像聚类，确保数据集覆盖多种缺陷和物体类型，相较于随机采样（覆盖不均），显著提升多样性。

(4) BERT文本校验：BERT通过语义相似度过滤重复或低质量描述，优于简单词汇匹配（如TF-IDF），提升标注质量。

此组合充分利用BLIP的生成能力、CLIP的匹配精度、ResNet的特征提取和BERT的语义分析，弥补单一技术的局限（如BLIP的领域偏差）。相较于基于缺陷先验知识的模板增强标注方法，本方法更倾向于平衡一致性和多样性，通过自监督和聚类适配MVTec数据集的多样化场景，支持泛化性强的下游任务。

3.2.2 自监督匹配标注流程步骤

方法的实现流程包括初始描述生成、自监督优化、多样性聚类和后处理校验四个步骤，如图3.3所示，具体如下：




图3.3 基于多模态预训练模型的自监督匹配标注流程

(1) 初始描述生成：利用预训练的多模态模型BLIP为MVTec图像生成初步文本描述。BLIP基于视觉-语言预训练，能够根据图像内容生成自然语言描述。对于一张螺丝图像，BLIP可能生成描述“金属螺丝表面有轻微划痕”。

(2) 自监督优化：为提升描述的语义一致性，采用CLIP模型计算初始描述与图像的匹配分数，通过余弦相似度评估图像-文本对的质量，公式同(2-16)。设定相似度阈值0.8，筛选高置信度样本作为伪标签，用于微调BLIP模型。微调采用对比损失函数：

$$L = -\sum \log \cos(v_I, v_T^+) + \log \sum \cos(v_I, v_T^-) \quad (2-17)$$

其中， v_T^+ 为正样本（高分描述）， v_T^- 为负样本（低分描述）。若第一次生成描述的CLIP分数低于0.8，则返回BLIP重新生成（调整提示，如“详细描述缺陷”），迭代最多3次。若仍不达标，样本标记为待人工审核。

(3) 多样性聚类：为增强数据集的多样性，基于预训练ResNet模型提取图像的视觉特征，采用K-means算法对MVTec图像进行聚类，聚类数量设为15（与数据集的物体类别数一致）。聚类确保数据集覆盖多种缺陷类型和物体类别。为每类图像生成多样化描述，通过提示工程控制BLIP输出不同风格的文本。例如，螺丝划痕图像可能生成“螺丝表面有线性划痕”或“螺丝上有一道细长擦伤”。

(4) 后处理校验：为确保标注质量，使用预训练的BERT模型计算生成描述间的语义相似度，过滤重复或高度相似的描述。描述不合格的图像重新进入BLIP生成与CLIP微调。三次迭代修改后仍没有描述保留的图像直接剔除。

表3.2 流程步骤与技术

步骤	输入	输出	条件
1.初始描述	图像	初步描述	BLIP模型
2.自监督优化	图像、描述	优化描述	CLIP+微调(迭代 ≤ 3 次)
3.多样性聚类	图像特征	聚类图像+多样化描述	ResNet+K-means
4.后处理校验	图像-文本对	去重	BERT模型

3.3 基于生成对抗网络的图像-文本协同标注方法

3.3.1 图像-文本协同标注方法概述

生成对抗网络是一种无监督学习模型，通过两个神经网络——生成器（Generator）和判别器（Discriminator）——的对抗训练，生成与真实数据分布高度相似的样本。生成器的目标是从随机噪声或输入条件生成逼真数据，判别器的目标是区分生成数据与真实数据。两者通过博弈达到纳什均衡，使生成器输出接近真实数据分布。在MVTec数据集的“图像-文本”多模态标注任务中，GAN可用于生成图像对应的文本描述，生成器（基于BLIP）生成描述，判别器（基于CLIP）评估图像-文本匹配度，通过对抗训练优化描述的语义一致性和多样性。

基于生成对抗网络的图像-文本协同标注算法利用GAN框架生成初始文本描述，通过外部知识库增强描述多样性，并结合CLIP模型校验和人工审核确保语义一致性与标注质量。其核心技术包括：BLIP模型作为生成器生成描述，CLIP模型作为判别器优化匹配，工业缺陷知识库扩充表达，CLIP校验与人工审核保障质量。相较于其他两种方法，本方法更倾向于追求多样性和技术创新，优先生成丰富的文本表达，适配MVTec数据集在复杂工业场景中的多样化需求。

技术特点在于：(1) 引入GAN对抗训练，突破传统生成模型（如BLIP）的语义一致性局限；(2) 结合知识库与多样性损失，显著提升文本表达的丰富性。

本方法通过分析传统生成方法的局限和多样化描述需求，确定了由GAN框架、知识库增强、多样性损失控制和CLIP校验组成的技术路线。MVTec的缺陷图像需丰富的文本表达以支持多样化下游任务（如跨场景检索），而纯BLIP生成受限于固定模式，人工标注无法满足多样性需求。技术组合的确定过程如下：

(1) GAN框架：GAN通过生成器（BLIP）和判别器（CLIP）的对抗训练优化图像-文本匹配，优于单向生成模型（如BLIP，语义一致性有限），能动态学习复杂语义关系，满足高一致性需求。

(2) 知识库增强：工业缺陷术语表和COCO风格提示提供多样化表达模板，优于单一提示生成（如LLaVA，领域适配性不足），显著提升描述的领域相关性和表达丰富性。

(3) 多样性损失控制：通过引入随机噪声和多样性损失（最大化文本特征余弦距离），优于固定生成策略（如模板生成，表达单一），确保描述风格多样。

(4) CLIP校验：CLIP的图像-文本匹配精度高于传统指标（如BLEU，语义评估不足），为GAN训练提供可靠监督，确保标注质量。

此组合充分利用GAN的对抗学习能力、知识库的领域知识、多样性损失的表达控制和CLIP的高精度校验，弥补单一生成模型的多样性不足。区别于前两种方法，本方法倾向于高多样性和技术创新，旨在探索MVTec复杂场景下的多样化描述，适合前沿研究和多样化任务。

3.3.2 图像-文本协同标注流程步骤

如图3.4所示，本方法的实现流程包括GAN框架对抗训练、知识库增强、多样性控制和质量过滤四个步骤，具体如下：

(1) GAN框架对抗训练：构建生成对抗网络，生成器基于预训练BLIP模型，输入MVTec图像生成初始文本描述；判别器基于CLIP模型，评估图像-文本对的匹配真实性。生成器目标是生成与图像高度匹配的描述，判别器则区分真实（高匹配度）与生成（低匹配度）图像-文本对。对抗训练优化以下目标函数：

$$\min_G \max_D \mathbb{E}_{(I,T) \sim p_{data}} [\log D(I,T)] + \mathbb{E}_{I \sim p_I} [\log(1 - D(I, G(I)))] \quad (2-18)$$

其中， G 为生成器， D 为判别器， I 为图像， T 为真实描述， $G(I)$ 为生成描述。训练过程中，CLIP计算图像-文本对的余弦相似度，若相似度低于阈值0.8，生成器调整生成策略（例如修改提示），迭代最多3次以优化描述质量。

(2) 知识库增强：为提升描述的领域相关性和多样性，引入外部知识库，包括工业缺陷术语表（例如“划痕”“凹痕”扩展为“表面擦伤”“圆形凹陷”）和COCO数据集的描述风格模板。知识库通过提示工程为生成器提供多样化输入，例如将“螺丝表面有划痕”扩展为“螺丝表面有一道线性擦伤”。知识库内容在每次迭代中动态选择，确保生成描述既符合工业场景，又具备丰富的表达形式。




图3.4 基于生成对抗网络的图像-文本协同标注流程

(3) 多样性控制：为进一步增强文本多样性，在生成器中引入随机噪声（例如高斯噪声），并优化多样性损失函数，最大化生成描述间的语义特征差异：

$$L_{div} = -\frac{1}{N} \sum_{i \neq j} \cos(v_{T_i}, v_{T_j}) \quad (2-19)$$

其中， v_{T_i} 和 v_{T_j} 为不同描述的文本特征， N 为描述数量。此损失鼓励生成器输出风格迥异的描述。多样性控制与知识库增强协同作用，确保数据集覆盖多样的文本表达。

表3.3 流程步骤与技术

步骤	输入	输出	条件
1. GAN对抗训练	图像	初始描述	BLIP+CLIP
2. 知识库增强	初始描述	领域相关描述	缺陷术语表+COCO模板
3. 多样性控制	描述	多样化描述	随机噪声+多样性损失
4. 质量过滤	图像-文本对	校验描述	CLIP+BERT

(4) 质量过滤：为保证标注质量，使用CLIP模型和BERT模型对生成描述进行最终校验，保留相似度高于0.8的图像-文本对，过滤重复描述。若某图像的描述不合格，则重新通过GAN框架生成描述。若3次迭代后仍不达标，剔除不合格样本。

3.4 本章小结

本章针对MVTec AD数据集的“图像-文本”多模态数据集构建需求，详细介绍了三种自动化标注方法，分别从不同技术路径解决语义一致性、标注质量和多样性问题。后续第四章将通过实验验证三种方法的有效性，构建三个数据集，评估其质量及下游任务性能，进一步分析技术路径对标注效果的影响，为多模态数据集构建提供参考。

第4章 评估与实验

为验证第三章提出的三种基于MVTec AD数据集的自动化标注方法的有效性，本章利用这三种方法对MVTec AD数据集进行文本标注，构建出相应的“图像-文本”多模态数据集进行实验，同时引入COCO子集作为对照组。实验通过指标评估量化三个“图像-文本”数据集在语义一致性、标注质量和文本多样性方面的表现，并通过图像描述生成和图像-文本检索两种任务测试其在下游任务中的性能。

4.1 实验设置

4.1.1 实验环境与数据集

实验在高性能计算平台上开展，硬件配置包括：NVIDIA RTX 4050 GPU, Intel(R)Core (TM)i7-14650HX CPU, 16GB内存。软件环境采用Python 3.9作为编程语言，PyTorch 1.12作为深度学习框架，Hugging Face Transformers 4.25用于预训练模型调用，scikit-learn 1.0用于聚类分析，Grammarly API用于语法评估。为保证实验一致性，所有方法在相同硬件和软件环境下运行。

实验以MVTec AD数据集为基础，包含15种工业物体类别，正常和缺陷图像共计约5000张图像。为满足实验需求，每种方法标注构建1万对“图像-文本”数据，通过图像增强和描述变体生成，确保类别均衡。数据集按照常规比例8:1:1划分为训练集8000对、验证集1000对和测试集1000对。此外，随机抽样选取COCO 2017数据集人工标注的1万对图像-文本子集作为对照组，用于比较自建数据集与人工标注数据集的质量和性能。所有数据包括图像路径、文本描述、CLIP分数以JSON格式存储在一起。

4.1.2 模型参数配置

实验采用以下核心模型，并明确参数设置：

(1) 缺陷检测：PatchCore模型（预训练于ImageNet，特征维度2048），用于模板增强方法的缺陷特征提取。

(2) 文本生成：BLIP模型（ViT-L/336基线，预训练于COCO+Web数据），用于三种方法的描述生成。微调参数：学习率 $1e-5$ ，批次大小32，Adam优化器，50个epoch。

(3) 匹配校验：CLIP模型（ViT-B/32，预训练于400M图像-文本对），用于计算图像-文本余弦相似度，阈值设为0.8。

(4) GAN训练: GAN协同方法中, BLIP作为生成器, CLIP作为判别器, 训练参数: 学习率 $2e-4$, 批次大小16, 100个epoch, Adam优化器。

(5) 聚类: K-means算法 ($k=15$, 基于ResNet-50提取的2048维特征), 用于自监督匹配方法的多样性增强。

(6) 文本去重: BERT模型 (base-uncased), 计算描述间语义相似度, 阈值为0.9。

4.1.3 评估指标

为系统评估三种自动化标注方法生成的数据集质量及其在下游任务中的性能, 本研究采用以下指标, 涵盖质量评估、任务性能和结果分析, 概念和计算方法如下:

(1) CLIP分数: 通过CLIP模型精确捕捉图像与文本描述的语义关联, 衡量描述是否忠实反映MVTec AD数据集的工业缺陷特征。其计算基于图像特征 v_I 和文本特征 v_T 的余弦相似度:

$$S = \cos(v_I, v_T) = \frac{v_I \cdot v_T}{\|v_I\| \|v_T\|} \quad (4-1)$$

取每种数据集的所有图像-文本对的CLIP分数平均值作为数据集的CLIP分数, 值范围为 $[0, 1]$, CLIP分数越高, 数据集的语义一致性越强, CLIP分数适用于评估数据集图像和文本描述的语义一致性。

(2) BLEU分数: 通过比较生成描述与参考描述的n-gram ($n=1-4$) 重叠率, 衡量文本的语法的正确性和语义的准确性。本文以COCO子集的人工描述作为参考, 计算公式为:

$$\text{BLEU} = \text{BP} \cdot \exp\left(\sum_{n=1}^4 w_n \log p_n\right) \quad (4-2)$$

其中 p_n 为第n-gram的裁剪精确度, w_n 为n-gram的权重 (通常为均等)。BP为短句惩罚因子。BLEU分数值范围为 $[0, 1]$, BLEU分数越高, 文本标注的质量越好。在图像描述生成任务中, BLEU分数衡量生成描述与参考描述的n-gram匹配度, 评估生成文本的准确性和流畅性。

(3) 词汇熵: 通过词汇频率分布刻画文本描述的表达多样性和语义丰富度, 适用于评估MVTec AD描述的多风格覆盖。计算公式为:

$$H = -\sum_{i=1}^n p(w_i) \cdot \log_2(p(w_i)) \quad (4-3)$$

其中 n 是词汇种类数, $p(w_i)$ 是第 i 个词汇的概率。

(4) CIDEr: 专为图像描述生成设计的指标, 通过TF-IDF加权n-gram匹配, 衡量生成描述与参考描述的语义共识, 强调人类标注的共性。计算公式为:

$$\text{CIDEr}_n = \frac{1}{m} \sum_{i=1}^m \frac{\mathbf{g}_n(c_i) \cdot \mathbf{g}_n(s_i)}{\|\mathbf{g}_n(c_i)\| \|\mathbf{g}_n(s_i)\|} \quad (4-4)$$

其中, c_i 为生成描述, s_i 为参考描述, $\mathbf{g}_n$ 为n-gram向量, m 为样本数。CIDEr的数值范围为 $[0, \infty]$, CIDEr的数值越高表示语义相关性越强。

(5) Recall@1和Recall@5: 图像-文本检索任务的召回率指标, 衡量正确文本或图像在检索结果前k位 ($k=1, 5$) 的比例, 反映检索精准性。计算公式为:

$$\text{Recall}@k = \frac{\text{正确匹配在前k位的样本数}}{\text{总样本数}} \quad (4-5)$$

数值范围为 $[0, 1]$, Recall@1和Recall@5的值越高表示检索性能越优。

(6) 皮尔逊相关系数: 通过线性相关性分析, 量化质量指标与任务性能的关联强度, 揭示因果关系。计算公式为:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (4-6)$$

其中, x_i 和 y_i 为变量观测值, $\bar{x}$ 和 $\bar{y}$ 为均值, n 为样本量, 数值范围 $[-1, 1]$, 正值表示正相关, 绝对值越大相关性越强。

4.2 数据集构建

4.2.1 数据集1: 模板增强标注

基于缺陷先验知识的模板增强标注方法对MVTec AD数据集的标注流程严格遵循图3.2所示的处理流程进行。最终构建出的模板增强标注的数据集规模、特性详见表4.1, 实验标注的伪代码详见算法1。具体的构建步骤和结果如下:

表4.1 模板增强标注数据集的规模特性

样本量:	约9600对 (剔除约4%未通过校验的样本)。
类别分布:	15种物体类别, 平均每类640对, 缺陷类型覆盖均匀
特性:	描述高度结构化, 语义一致性高, 词汇量适中 (约1000词), 表达风格较为统一。
模板(部分):	1. The surface of [object] has a [defect type] at [location], with a [shape] shape. 2. [Object] has a [defect type] at [location], with a [shape] shape and [extent] extent. 3. A [shape] [defect type] appears on the [location] of [object].

算法1：模板增强标注方法

输入：MVTecDataset（10000张图像及掩码）

输出：Dataset1（9600个图像-文本对）

```

1  Dataset1 ← {}# 初始化空数据集
# 预处理并提取特征
2  Images ← PreprocessImages(MVTecDataset) # 扩展10000张
3  For each Image, Mask in Images:
4      Metadata ← ExtractMetadata(Image) # 生成JSON元数据
5      Defects ← PatchCoreDetect(Image, Mask, dim=2048, threshold=0.95) # 提取缺陷特征
6      UpdateMetadata(Image, Defects) # 更新JSON
# 生成并改写描述
7  For each Image in Images:
8      Defects ← GetDefects(Image, Metadata) # 获取缺陷
9      InitialDescs ← GenerateTemplates(Defects, num=2) # 2条初步英文描述
10     Descs ← LLaVA_Rewrite(InitialDescs, prompt="生成精确、多样的英文描述", num=3)
11     ValidDescs ← []
12     For Iteration from 1 to 3:
13         For each Desc in Descs:
14             If CLIP_Score(Image, Desc) ≥ 0.8:
15                 ValidDescs.append((Desc, Score)) # 存储合格描述
16         If ValidDescs is not empty:
17             Break # 退出迭代
18         Defects ← PatchCoreDetect(Image, Mask, dim=2048, threshold=0.95) # 重提取特征
19         InitialDescs ← GenerateTemplates(Defects, num=2)
20         Descs ← LLaVA_Rewrite(InitialDescs, prompt="生成精确、多样的英文描述", num=3)
21     If ValidDescs is empty:
22         Continue # 剔除图像（400张）
23     BestDesc ← SelectHighestScore(ValidDescs) # 保留最高分描述
24     Dataset1[Image] ← BestDesc # 添加到数据集（9600对）
25 返回 Dataset1 # 返回9600对

```

(1) 对MVTec AD数据集中的图像进行预处理，将原本的5000张扩展到10000张，提取每张图像的元数据，包括标识（image_id）、路径（image_path）、物体类别（category，如“bottle”）、数据集划分（split，如“test”）和状态（status，如“defective”），并以JSON格式存储，形成结构化的初步数据集用以后续阶段的标注。

(2) PatchCore通过2048维的特征提取和0.95的异常评分阈值对扩展后数据集进行处

理，精细捕捉提取每一张图像的缺陷特征，并根据捕获的缺陷特征生成包含缺陷类型（如“broken_large”）、位置（如“side”）、形状（如“irregular”）和程度（如“large”）在内的结构化信息，并将这些信息扩展到初步构建的JSON文件中。

(3) 结合预定义的多样化模板和PatchCore捕获的缺陷特征为每张图像生成两条初步描述文本，总共约2万条描述候选。LLaVA模型通过提示工程（如“Generate precise, varied English descriptions”）对上面的描述候选进行改写扩展生成3万条候选，增强表达多样性。此时10000张图像中的每一张都有3条描述。

(4) 改写后利用CLIP模型对每条描述进行校验，筛选去除品质较低的描述。三条描述都无法通过CLIP校验的图像重新使用PatchCore算法提取特征进行生成，三次迭代修改都无法通过CLIP校验的图像文本对直接剔除。其余描述通过CLIP校验的图像如果有两条及以上的描述合格，则保留CLIP分数最高的一条描述进入最终数据集。最后标注完成的数据集1中图像“bottle_test_defective_broken_large_000”的元数据如图4.1所示。

```
{
  "image_id": "bottle_test_defective_broken_large_000",
  "image_path": "processed_images\\bottle_test_defective_broken_large_000.png",
  "category": "bottle",
  "split": "test",
  "status": "defective",
  "defect": {
    "type": "broken_large",
    "location": "side",
    "shape": "irregular",
    "extent": "large"
  },
  "description": {
    "text": "The surface of a bottle has a large break at the side, with an irregular shape",
    "clip_score": 0.82
  }
},
```

图4.1 数据集1中的元数据

4.2.2 数据集2：自监督匹配标注

基于多模态预训练模型的自监督匹配标注方法对MVTec AD数据集的标注流程遵循图3.3所示的处理流程进行。最终构建出的自监督匹配标注的数据集规模、特性详见表4.2，实验标注的伪代码详见算法2。具体的构建步骤和结果如下：

表4.2 自监督匹配标注数据集的规模特性

样本量：	约9400对（剔除约6%低质量样本）。
类别分布：	15种物体类别，聚类确保每类至少600对，缺陷类型分布均衡。
特性：	描述自然且多样，一致性和多样性平衡，词汇量较高（约1500词）。

算法2：模板增强标注

输入：MVTecDataset（5000张图像及掩码）

输出：Dataset2（9400个图像-文本对）

初始化空数据集

1 Dataset2 $\leftarrow$ {}

预处理并提取元数据

2 Images $\leftarrow$ PreprocessImages(MVTecDataset) # 扩展10000张

3 Metadata $\leftarrow$ ExtractMetadata(Images) # 生成JSON元数据

步骤2：BLIP生成与CLIP微调

4 Descs $\leftarrow$ BLIP_Generate(Images, num=1) # 每张生成1条英文描述（10000条）

5 PseudoLabels $\leftarrow$ CLIP_Filter(Images, Descs, threshold=0.8) # 筛选8000条伪标签

6 BLIP_Model $\leftarrow$ FineTune_BLIP(PseudoLabels, loss="cross_entropy", lr=1e-5, epochs=10)

7 Descs $\leftarrow$ BLIP_Model.Generate(Images, num=1) # 生成优化描述（10000条）

步骤3：ResNet聚类与描述扩展

8 Features $\leftarrow$ ResNet_Extract(Images, dim=2048) # 提取特征

9 Clusters $\leftarrow$ KMeans_Cluster(Features, k=15) # 15类聚类

10 NewDescs $\leftarrow$ BLIP_Model.Generate(Clusters, num=1-2) # 每张1-2条描述（15000条）

11 Descs $\leftarrow$ Descs + NewDescs # 合并描述

步骤4：CLIP校验与BERT去重

12 ValidDescs $\leftarrow$ []

13 For each Image in Images:

14 ImageDescs $\leftarrow$ GetDescs(Image, Descs) # 获取描述

15 For each Desc in ImageDescs:

16 If CLIP_Score(Image, Desc) $\geq$ 0.8:

17 ValidDescs.append((Image, Desc, Score)) # 存储合格描述

18 ValidDescs $\leftarrow$ BERT_Deduplicate(ValidDescs, model="all-MiniLM-L6-v2", threshold=0.9)

19 For each Image in ValidDescs:

20 BestDesc $\leftarrow$ SelectHighestScore(Image, ValidDescs) # 保留最高CLIP分描述

21 Dataset2[Image] $\leftarrow$ BestDesc # 添加到数据集

22 返回 Dataset2 # 返回9400对

(1) 对MVTec AD数据集中的图像进行预处理，方法与4.2.1小节中的模板增强标注方法的预处理一致，将原本的5000张扩展到10000张，提取每张图像的元数据以JSON格式存储，形成结构化的初步数据集用以后续阶段的标注。

(2) 利用BLIP模型为扩展到数据集的每一张图像都生成一条初始描述文本，共10000条候选（如“A bottle with a defect on the side”）。采用CLIP模型计算图像-描述对的余弦相似度，筛选高置信度伪标签（阈值0.8，基于预实验确保80%描述与图像匹配），

生成约8000条伪标签对（图像-描述）。以伪标签为监督数据对BLIP进行自监督微调和优化交叉熵损失（批次大小16，学习率 $1e-5$ ，训练10个epoch，Adam优化器），提升描述的语义一致性和标注质量，生成优化后的10000条描述。

(3) 使用ResNet-50模型提取10000张图像的2048维特征向量，采用k-means算法基于MVTec的15种物体类别及缺陷类型分布进行聚类分析，增强样本的类别覆盖率和表达多样性。利用BLIP模型针对每个聚类再生成2条补充英文描述（如“A screw with a slight scratch on the surface”），共生成约3万条候选描述（每张图像3条），进一步丰富语义表达。

(4) 采用CLIP模型对3万条候选描述进行一致性校验，剔除其中语义不匹配的描述。利用BERT模型过滤其中重复或冗余的文本描述（阈值0.9，基于预实验确保语义唯一性）。3条描述都无法保留的图像重新进入BLIP生成与CLIP微调。三次迭代修改后仍没有一条描述保留的图像直接剔除。其余描述通过校验的图像如果有两条及以上的描述合格，则保留CLIP分数最高的描述进入最终数据集。最终数据集2中图像“bottle_test_defective_broken_large_000”的元数据如图4.2所示。

```
{
  "image_id": "bottle_test_defective_broken_large_000",
  "image_path": "/path/to/mvttec/bottle/test/defective/broken_large/000.png",
  "category": "bottle",
  "split": "test",
  "status": "defective",
  "description": "A bottle with a large broken area on the side",
  "clip_score": 0.85,
  "cluster_id": "bottle_broken"
},
```

图4.2 数据集2中的元数据

4.2.3 数据集3：GAN协同标注

基于生成对抗网络的图像-文本协同标注方法对MVTec AD数据集的标注流程按图3.4所示的处理流程进行。最终构建出的GAN协同标注数据集规模与特性详见表4.3，实验标注的伪代码详见算法3。具体的构建步骤和结果如下：

(1) 与前两节标注方法一致，对MVTec AD数据集的5000张图像进行相同的预处理，通过数据增强扩展至10000张，同时提取每张图像的元数据进入JSON文件，作为初始的数据集。

(2) 采用生成对抗网络（GAN）框架，BLIP模型作为生成器，为10000张图像生成初始描述文本，每张生成1条作为初始候选。CLIP模型作为判别器，评估初始候选的图像-文本对的语义一致性，通过对抗训练（交叉熵损失，学习率 $1e-5$ ，批次大小16，训练10个epoch，Adam优化器）优化生成器，生成更精准的10000条描述。

算法3：自监督匹配标注方法

输入：MVTecDataset（10000张图像及掩码）

输出：Dataset3（4600个图像-文本对）

```

1  Dataset3 ← {} # 初始化空数据集
# 预处理图像
2  Images ← PreprocessImages(MVTecDataset) # 扩展10000张
3  Metadata ← ExtractMetadata(Images) # 生成JSON元数据
# GAN生成初始描述
4  Descs ← BLIP_Generate(Images, num=1) # 生成描述（10000条）
5  GAN ← Train_GAN(BLIP, CLIP, lr=1e-5, epochs=10) # 对抗训练
6  Descs ← GAN.Generate(Images, num=1) # 优化描述
# 知识库增强与多样性控制
7  For each Image in Images:
8      NewDescs ← KnowledgeEnhance(Descs[Image], defect_terms, coco_styles, num=1-2)
9      Descs[Image] ← ApplyDiversityLoss(NewDescs, cos_threshold=0.7) # 控制多样性
# CLIP校验与筛选
10 For each Image in Images:
11     ValidDescs ← []
12     ImageDescs ← Descs[Image] # 获取描述
13     For Iteration from 1 to 3:
14         If any CLIP_Score(Desc, Image) ≥ 0.8 for Desc in ImageDescs:
15             ValidDescs ← [Desc for Desc in ImageDescs if CLIP_Score(Desc, Image) ≥
0.8]
16             Break # 退出迭代
17     ImageDescs ← GAN.Generate(Image, prompt="精确的英文描述", num=3)
18     If ValidDescs is empty:
19         Continue # 剔除图像（5400张）
20     BestDesc ← DeduplicateAndSelect(ValidDescs, sim_threshold=0.9) # 去重选最高分
21     Dataset3[Image] ← BestDesc # 添加到数据集
22 返回 Dataset3 # 返回9200对

```

表4.3 GAN协同标注数据集的规模特性

样本量:	约9200对（剔除约8%未通过校验的样本）。
类别分布:	15种物体类别，每类约600对，知识库增强覆盖多种缺陷表达。
特性:	描述风格丰富，多样性最高，词汇量最大（约2000词），一致性略低于数据集1。

(3) 基于缺陷术语表和COCO风格提示，在初始候选的基础上再为每张图像生成2条补充描述，共约2万条，结合初始候选形成3万条候选。引入多样性损失（最大化文本特

征余弦距离，阈值0.7)，控制描述风格多样性，增强语义表达丰富度。

(4) 对3万条描述进行CLIP校验，并利用BERT模型过滤其中重复或冗余的文本描述。若某图像的三条描述均不合格，则重新通过GAN框架生成描述，迭代3次之后仍不合格的图像从数据集中剔除。剩余图像若有2条及以上描述合格，保留CLIP分数最高的一条。最终数据集3中图像“bottle_test_defective_broken_large_000”的元数据如图4.3所示。

```
{
  "image_id": "bottle_test_defective_broken_large_000",
  "image_path": "/mnt/data/mvtec_ad/bottle/test/defective/broken_large_000.png",
  "category": "bottle",
  "split": "test",
  "status": "defective",
  "description": "A bottle with a large irregular break on the side",
  "clip_score": 0.83
},
```

图4.3 数据集3中的元数据

4.2.4 数据集4：COCO子集

COCO子集的构建直接从COCO 2017数据集抽取1万张图像，并引用人工标注描述，统一文本格式确保与MVTec AD数据集风格一致。最终构建出的COCO子集的规模、特性和实验的伪代码详见算法4。

算法4：COCOSubsetConstruction

输入: COCO2017Subset (set of images and annotations)

输出: COCOSubset (set of image-text pairs)

- 1 Initialize COCOSubset as empty set // 初始化COCO子集为空集合
 - 2 For each Image, Annotations in COCO2017Subset:
 - 3 SelectedDesc $\leftarrow$ SelectDescription(Annotations) // 随机选择一条英文描述
 - 4 FormattedDesc $\leftarrow$ FormatDescription(SelectedDesc) // 统一描述格式
 - 5 Add (Image, FormattedDesc) to COCOSubset // 添加到COCO子集
 - 6 Return COCOSubset // 返回COCO子集
-

表4.4 COCO子集的规模特性与伪代码

样本量:	1万对（每张图像1条描述）
类别分布:	80类物体，类别分布随机，场景复杂（非工业）。
特性:	描述自然、人工标注质量高，词汇量丰富（约5000词），但缺乏MVTec的工业领域相关性。

4.3 数据集质量评估

本节通过计算CLIP分数、BLEU和词汇熵量化数据集的语义一致性、标注质量和文

本多样性，评估四种数据集的质量。表4.5汇总了各数据集的评估结果，图4.1则对四个数据集的CLIP分数、BLEU分数、词汇熵进行了直观比较，现对结果分析如下：

(1) COCO子集得益于人工标注的高精度和通用场景的丰富表达，CLIP分数、BLEU分数和词汇熵三项指标均优于自动标注的三个“图像-文本”数据集。




图4.1 不同数据集CLIP分数、BLEU分数、词汇熵比较

(2) 如图4.1(a)所示，数据集1的CLIP分数是实验构建的三个数据集中最高的，直接表明由模板增强方法进行标注的数据集在语义一致性方面比较突出。但数据集1的BLEU分数和词汇熵低于其它两个数据集的事实也暴露了这种方法还有一些不足之处。预设模板的固定格式严格限制了标注文本表达的多样性，也导致数据集1的词汇熵在三个数据集中最低。同时，工业描述风格与COCO通用风格的差异让数据集1的BLEU分数偏低，同样位列三个数据集之末。

(3) 数据集2的BLEU分数相较于其它两个数据集更接近COCO标准，如图4.1(b)所示，这反映出了数据集2标注的文本描述十分的自然流畅。而数据集2的CLIP分数与词汇熵在三个数据集中均处于中等，显示出数据集2对标注一致性与文本多样性的平衡做的比较好。或许是因为流程中自监督微调的步骤引入了少量偏差，导致数据集2的一致性略低。

表4.5 数据集质量评估结果

数据集	CLIP分数	BLEU分数	词汇熵
数据集1（模板）	0.85 ± 0.02	0.65 ± 0.03	3.2 ± 0.1
数据集2（自监督）	0.82 ± 0.02	0.70 ± 0.03	4.0 ± 0.1
数据集3（GAN）	0.80 ± 0.03	0.68 ± 0.03	4.8 ± 0.1
COCO子集	0.90 ± 0.01	0.85 ± 0.02	5.5 ± 0.1

(4) GAN协同标注的数据集3的CLIP分数是构建的三个数据集中最低的，这显示出数据集3文本标注的一致性较低。但数据集3的词汇熵又远高于其它两个数据集，显示出文本表述的丰富多样性比较强。分析GAN协同方法的标注流程可以看到，数据集3利用

GAN对抗训练和知识库增强生成了丰富多样的描述，但GAN训练的复杂性可能导致少量的语义偏差，得到的CLIP分数略低。

4.4 下游任务验证

为了验证4.3节构建的三个数据集及COCO子集对照组在实际应用中的表现，本节通过图像描述生成和图像-文本检索两项下游任务系统评估它们的性能表现和适用性。

4.4.1 任务设置与流程

图像描述生成任务要求模型根据输入图像生成与其内容高度匹配的自然语言描述。生成的文本描述需在语义上准确反映图像内容，同时具备流畅的语言表达。评估指标采用BLEU和CIDEr。图像-文本检索任务要求模型在图像到文本和文本到图像的双向检索中实现高效匹配，即从大规模候选集中检索出与查询最相关的图像或文本。评估指标包括Recall@1和Recall@5。

实验相关设置详见表4.6和表4.7，其中包括模型超参数、优化器选择、学习率调度、批次大小以及训练轮数等关键信息。实验的核心算法流程通过伪代码形式呈现，详见算法5和算法6。每种数据集重复训练和测试3次，取平均值，标准差控制在 ± 0.02 ，确保结果稳定性；对照组COCO子集使用相同模型和设置，比较工业与通用场景性能。

表4.6 图像描述生成任务相关设置

模型:	BLIP模型 (ViT-B/32 backbone)
数据集划分:	每种数据集按8:1:1划分训练集、验证集和测试集。数据集1-3分别为7680/960/960、7520/940/940、7360/920/920对，COCO子集为8000/1000/1000对。
训练:	在每种数据集的训练集上微调BLIP，优化交叉熵损失，批次大小16，学习率 $1e-5$ ，训练10个epoch，使用Adam优化器。
测试:	在测试集上生成描述，计算BLEU (n=1-4) 和CIDEr分数，与COCO子集的人工标注描述作为参考。

表4.7 图像-文本检索任务相关设置

模型:	CLIP模型 (ViT-B/32)
数据集划分:	每种数据集按8:1:1划分训练集、验证集和测试集。数据集1-3分别为7680/960/960、7520/940/940、7360/920/920对，COCO子集为8000/1000/1000对。
训练:	在每种数据集的训练集上微调CLIP，优化对比损失，批次大小32，学习率 $1e-5$ ，训练5个epoch，使用Adam优化器。
测试:	在测试集上执行双向检索（图像到文本、文本到图像），计算Recall@1（前1位召回率）和Recall@5（前5位召回率）。

算法5: 图像描述生成任务

输入: TestDataset (图像-参考描述对集合), Model (BLIP模型)

输出: AvgBLEU (平均BLEU分数), AvgCIDEr (平均CIDEr分数)

初始化分数列表

1 BLEUScores $\leftarrow$ []

2 CIDErScores $\leftarrow$ []

遍历测试集

3 For each Image, RefDesc in TestDataset:

4 GenDesc $\leftarrow$ Model.Generate(Image) # 生成英文描述

5 BLEU $\leftarrow$ ComputeBLEU(GenDesc, RefDesc, n=1-4) # 计算BLEU分数

6 CIDEr $\leftarrow$ ComputeCIDEr(GenDesc, RefDesc) # 计算CIDEr分数

7 BLEUScores.append(BLEU) # 添加BLEU分数

8 CIDErScores.append(CIDEr) # 添加CIDEr分数

计算平均分数

9 AvgBLEU $\leftarrow$ Mean(BLEUScores) # 平均BLEU分数

10 AvgCIDEr $\leftarrow$ Mean(CIDErScores) # 平均CIDEr分数

11 返回AvgBLEU, AvgCIDEr # 返回平均分数

算法6: 图像-文本检索任务

输入: TestDataset (图像-文本对集合), Model (CLIP模型)

输出: Recall@1 (平均首位召回率), Recall@5 (平均前5位召回率)

初始化分数列表

1 Scores $\leftarrow$ []

遍历测试集

2 For each Image, Text in TestDataset:

3 ImgRank $\leftarrow$ Model.RankTexts(Image, TestDataset.Texts) # 图像到文本排名

4 TextRank $\leftarrow$ Model.RankImages(Text, TestDataset.Images) # 文本到图像排名

5 R1 $\leftarrow$ 1 if ImgRank[1] == Text and TextRank[1] == Image else 0 # Recall@1

6 R5 $\leftarrow$ 1 if Text in ImgRank[1:5] and Image in TextRank[1:5] else 0 # Recall@5

7 Scores.append((R1, R5)) # 添加分数

计算平均召回率

8 Recall@1 $\leftarrow$ Mean([s[0] for s in Scores]) # 平均Recall@1

9 Recall@5 $\leftarrow$ Mean([s[1] for s in Scores]) # 平均Recall@5

10 返回 Recall@1, Recall@5 # 返回召回率

4.4.2 任务结果

基于上述设置，四种数据集在图像描述生成和图像-文本检索任务中的性能结果如下，表4.8和表4.9分别汇总描述生成和检索指标，4.2和4.3则分别对四个数据集的BLEU分数和CIDEr分数、Recall@1和Recall@5进行了直观比较。




图4.2 不同数据集在图像描述生成任务下的表现

表4.8 图像描述生成性能

数据集	BLEU	CIDEr	特性分析
数据集1 (模板)	0.62	0.75	高一致性，表达单一
数据集2 (自监督)	0.68	0.82	平衡一致性与多样性
数据集3 (GAN)	0.65	0.78	风格丰富，一致性稍低
COCO子集	0.85	1.10	高质量，缺乏工业相关性

(1) 图像描述生成结果：模板增强标注的数据集1的BLEU和CIDEr都比较低，这个数据集的描述比较结构化，一致性高的同时，多样性较低也导致了生成表达较为单一，在图像描述生成的任务里不如其它两个数据集。自监督匹配标注数据集2表现最好，BLEU和CIDEr均为三个数据集之最，初步推断是由于数据集2的标注的一致性和文本的多样性平衡做的比较好，生成的文本描述自然。GAN协同标注的数据集3生成的描述风格丰富，但一致性稍低影响BLEU值。

(2) 图像-文本检索结果：模板增强标注的数据集1在图像-文本检索任务表现最好，指标Recall@1和Recall@5为三个数据集之最，初步推断高一致性能够更好的支持精准匹配。自监督匹配标注的数据集2标注的一致性和文本的多样性平衡做的比较好，在图像-文本检索任务上的表现虽然逊色于数据集1，但比GAN协同标注的数据集3表现得好。GAN协同标注的数据集3在图像-文本检索任务上的表现最差，Recall@1和Recall@5为三个数据集垫底。




图4.3 不同数据集在图像-文本检索任务下的表现

表4.9 图像-文本检索任务性能

数据集	Recall@1	Recall@5	特性分析
数据集1（模板）	0.78	0.92	高一致性，工业精准
数据集2（自监督）	0.75	0.90	平衡一致性与多样性
数据集3（GAN）	0.72	0.88	多样性强，一致性稍低
COCO子集	0.88	0.95	高召回，缺乏工业相关性

4.5 方法特性总结

4.5.1 任务中质量指标的影响分析

为揭示数据集质量对下游任务性能的因果作用，本节通过分析三个质量指标在图像描述生成和图像-文本检索任务中的影响及其交互作用来进行探讨分析。

(1) 图像描述生成任务中的质量指标影响：

根据图4.2不同数据集在图像描述生成任务下的表现，自监督匹配方法标注的数据集2在描述生成任务中表现仅次于COCO子集，优于其他两个数据集。推测其优异表现源于数据集2在语义一致性与文本多样性间的有效平衡。而为量化质量指标CLIP分数、BLEU和词汇熵与描述生成任务性能BLEU/CIDEr的关联强度并揭示因果关系，计算了皮尔逊相关系数，如表4.10所示。

结果显示，数据集的BLEU分数和词汇熵与生成任务的BLEU、CIDEr相关系数均 ≥ 0.85 ，呈强正相关性，而CLIP分数相关系数较低，关联较弱。分析原因为高BLEU分数反映描述的语法正确性和流畅性，直接提升生成模型的学习效果；而高词汇熵提供了丰富的语义覆盖，增强了模型生成表达的多样性和语义准确性。数据集1的模板描述因为表达单一导致生成质量较低。

表4.10 图像描述生成任务的皮尔逊相关系数

质量指标	描述生成BLEU	描述生成CIDEr
CLIP分数	0.79	0.82
数据集BLEU	0.91	0.89
词汇熵	0.87	0.85

(2) 图像-文本检索任务中的质量指标影响:

基于对图4.3不同数据集在图像-文本检索任务下的表现的分析,可以看到数据集1在这项任务的表现最好,数据集2和数据集3的表现差一点。为了分析质量指标CLIP分数、BLEU和词汇熵对Recall@1和Recall@5的影响,现在通过计算皮尔逊相关系数深入探讨其优异表现的内在机制,如表4.11所示。

表4.11 图像-文本检索任务的皮尔逊相关系数

质量指标	检索Recall@1	检索Recall@5
CLIP分数	0.91	0.89
数据集BLEU	0.65	0.70
词汇熵	0.72	0.87

结果表明,CLIP分数与Recall@1和Recall@5的相关系数均 ≥ 0.85 ,呈现强正相关性,而BLEU分数和词汇熵的相关系数较低,关联较弱。分析原因,数据集1通过PatchCore和模板生成精确描述,高CLIP分数能够确保图像-文本精准匹配,驱动检索性能支持高效的图像-文本检索。多样描述能够覆盖更多匹配场景,较高的词汇熵能够提升广义召回率。BLEU对检索影响较小,因为检索更依赖语义匹配而非语法流畅性。

4.5.2 方法优劣与倾向性分析

基于质量和性能结果,并结合4.3节的质量指标和4.4节的任务表现,对三种自动标注方法进行综合分析,评估其在MVTec AD工业场景中的优劣、适用场景及与COCO子集的差距:

(1) 基于缺陷先验知识的模板增强标注方法:模板增强方法标注的数据集1展现了卓越的语义一致性,该方法依托缺陷先验和结构化模板生成精准描述(如“A screw with a scratch on the top”),在图像-文本检索任务中表现最佳,接近COCO子集。然而,其低多样性限制描述生成性能,模板固定性难以适配复杂场景,适合工业标准化任务,如缺陷分类。

(2) 基于多模态预训练模型的自监督匹配标注方法:自监督匹配方法标注的数据集2平衡一致性和多样性,该方法通过微调和聚类生成自然描述(如“A screw with a slight

scratch on the surface”)，在描述生成任务中表现最佳，接近COCO子集，检索性能稳定。其标注质量支持流畅表达，生成9400对数据，但微调需较高计算资源，精准检索略逊于数据集1。该方法适配多样化任务，如跨场景生成和检索。

(3) 基于生成对抗网络的图像-文本协同标注方法：GAN协同方法标注的数据集3以多样性见长，该方法通过对抗训练和知识库生成多风格描述（如“A screw with a linear scratch on the top”），生成性能良好，检索Recall@5较高，生成9200对数据。然而，其一致性稍低，因为GAN可能引入偏差，精准检索受限，训练复杂性高。该方法适合复杂场景和前沿研究。

4.6 本章小节

本章通过系统的实验验证了第三章提出的三种自动化标注方法的有效性，基于MVTec AD数据集构建并评估了三个高质量“图像-文本”多模态数据集，以COCO子集为对照组，量化其在语义一致性、标注质量和多样性及下游任务性能上的表现。

实验结果表明，数据集1（模板增强）具有高一一致性和标注效率，检索性能最佳，适合工业标准化任务，但多样性较低。数据集2（自监督匹配）平衡一致性和多样性，描述生成领先，适配多样化场景。数据集3（GAN协同）多样性最强，支持复杂场景，但一致性稍低。三种方法均有效解决了语义一致性、标注质量和多样性问题。

结论

本论文针对多模态学习中高质量“图像-文本”数据集构建的挑战，基于MVTec AD数据集，提出并验证了三种自动化标注方法：基于缺陷先验知识的模板增强标注、基于多模态预训练模型的自监督匹配标注和基于生成对抗网络的图像-文本协同标注。研究旨在解决语义一致性、标注质量和文本多样性三大核心问题，为图像描述生成和图像-文本检索等下游任务提供优质数据支持。

实验通过构建三个数据集（数据集1：9600对，数据集2：9400对，数据集3：9200对）及COCO子集对照组的1万对，评估其质量，并分析质量与性能关系。

主要研究成果如下：

(1) 模板增强标注方法：这种方法利用PatchCore提取先验知识并结合结构化模板，完成了高一致性的文本描述，在图像-文本检索任务中表现仅次于COCO子集，效率高且人工审核成本低。该方法倾向于工业标准化任务，适配MVTec AD的精准描述需求，但多样性较低限制了描述生成性能。

(2) 自监督匹配标注方法：这种方法通过对BLIP的微调和ResNet聚类平衡文本标注的一致性和多样性，能够适配多样化场景，在描述生成任务中领先。这种方法适配多样化下游任务，但微调需较高计算资源，精准检索略逊于模板增强标注方法。

(3) GAN协同标注方法：这种方法借助GAN对抗训练和知识库增强文本描述多样性生成多样化描述，能够支持复杂场景，在复杂场景生成和广义检索中表现都比较好。但标注的一致性稍低，训练复杂性较高。

尽管本研究在MVTec AD工业场景中取得显著成果，但仍有优化空间。模板增强方法可通过扩展模板字段或引入动态模板生成提升词汇熵增强描述生成性能，同时优化LaVA改写以降低模型依赖。自监督匹配方法可采用轻量化微调或增量学习策略减少计算资源需求，改进聚类算法以覆盖更多缺陷类型提升一致性。GAN协同方法可通过正则化优化训练稳定性提高一致性，并扩展知识库支持更复杂场景。未来研究将围绕这些方向，开发更高效、鲁棒的自动化标注技术，为多模态学习提供优质数据支撑。

参考文献

- [1] Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context[C]//Computer vision–ECCV 2014: 13th European conference, zurich, Switzerland, September 6-12, 2014, proceedings, part v 13. Springer International Publishing, 2014: 740-755.
- [2] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PmLR, 2021: 8748-8763.
- [3] Li J, Li D, Xiong C, et al. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation[C]//International conference on machine learning. PMLR, 2022: 12888-12900.
- [4] Alayrac J B, Donahue J, Luc P, et al. Flamingo: a visual language model for few-shot learning[J]. Advances in neural information processing systems, 2022, 35: 23716-23736.
- [5] Huo Y, Zhang M, Liu G, et al. WenLan: Bridging vision and language by large-scale multi-modal pre-training[J]. arXiv preprint arXiv:2103.06561, 2021.
- [6] Lin J, Men R, Yang A, et al. M6: A chinese multimodal pretrainer[J]. arXiv preprint arXiv:2103.00823, 2021.
- [7] Luo H, Ji L, Shi B, et al. Univl: A unified video and language pre-training model for multimodal understanding and generation[J]. arXiv preprint arXiv:2002.06353, 2020.
- [8] Krishna R, Zhu Y, Groth O, et al. Visual genome: Connecting language and vision using crowdsourced dense image annotations[J]. International journal of computer vision, 2017, 123: 32-73.
- [9] Liang P P, Zadeh A, Morency L P. Foundations & trends in multimodal machine learning: Principles, challenges, and open questions[J]. ACM Computing Surveys, 2024, 56(10): 1-42.
- [10] Bergmann P, Fauser M, Sattlegger D, et al. MVTec AD--A comprehensive real-world dataset for unsupervised anomaly detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 9592-9600.
- [11] Chen A, Wang Z, Dong C, et al. Chinaopen: A dataset for open-world multimodal learning [C]//Proceedings of the 31st ACM International Conference on Multimedia. 2023: 6432-6440.
- [12] Yuan S, Zhao S, Leng J, et al. Wudaomm: A large-scale multi-modal dataset for pre-

- p>training models[J]. arXiv preprint arXiv:2203.11480, 2022.
- [13] 范家斌,王宝会,陈继轩.基于文本-图像多模态融合的变电所布局图纸图符检测方法[J/OL].计算机科学, 2025: 1-16.
- [14] Gu J, Meng X, Lu G, et al. Wukong: A 100 million large-scale chinese cross-modal pre-training benchmark[J]. Advances in Neural Information Processing Systems, 2022, 35: 26418-26431.
- [15] Ratner A, Bach S H, Ehrenberg H, et al. Snorkel: Rapid training data creation with weak supervision[C]//Proceedings of the VLDB endowment. International conference on very large data bases. 2017, 11(3): 269.
- [16] Lee D H. Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks[C]//Workshop on challenges in representation learning, ICML. 2013, 3(2): 896.
- [17] 孙锐,杜云,陈龙,等.隐式多尺度对齐与交互的文本-图像行人重识别方法[J/OL].软件学报, 2025, 11(3): 1-18.
- [18] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.
- [19] Peng C, Sheng Y, Gui W, et al. A rolling bearing fault diagnosis method based on multimodal knowledge graph[J]. IEEE Transactions on Industrial Informatics, 2024.
- [20] 陶显,侯伟,徐德.基于深度学习的表面缺陷检测方法综述[J].自动化学报, 2021, 47(5): 1017-1034..
- [21] Qu X, Liu Z, Wu C Q, et al. Mfgan: multimodal fusion for industrial anomaly detection using attention-based autoencoder and generative adversarial network[J]. Sensors, 2024, 24(2): 637.
- [22] 魏忠钰, 范智昊, 王瑞泽, 等. 从视觉到文本: 图像描述生成的研究进展综述[J]. 中文信息学报, 2020, 34(7): 19-29.
- [23] 王志颖,汪西莉.轻量化文本图像多模态遥感图像语义分割模型[J/OL].激光与光电子学进展, 2025, 34(3): 1-18.
- [24] Cheng H, Luo J, Zhang X. Multimodal Industrial Anomaly Detection via Uni-Modal and Cross-Modal Fusion[J]. IEEE Transactions on Industrial Informatics, 2025.
- [25] Wang B, Liu D, Peng X, et al. Data-driven anomaly detection of UAV based on multimodal regression model[C]//2019 IEEE International Instrumentation and Measurement Technology Conference (I2MTC). IEEE, 2019: 1-6.

- [26] 张新生,陈鼎,秦一冰.基于CLIP文本特征增强的剪纸图像分类[J/OL].计算机应用研究, 2025, 36(3): 1-10.
- [27] Liu H, Li C, Wu Q, et al. Visual instruction tuning[J]. Advances in neural information processing systems, 2023, 36: 34892-34916.
- [28] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.
- [29] Roth K, Pemula L, Zepeda J, et al. Towards total recall in industrial anomaly detection[C] //Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 14318-14328.
- [30] MacQueen J. Some methods for classification and analysis of multivariate observations[C] //Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, Volume 1: Statistics. University of California press, 1967, 5: 281-298.
- [31] 蒋婷婷,徐澳,吴飞飞,等.基于“图像-文本”间关联增强的多模态猪病知识图谱融合方法[J].农业机械学报,2025,56(01):56-64.
- [32] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.
- [33] 王旭峰,周迪,张风雷,等.基于多粒度对齐网络的图像-文本匹配方法[J/OL].山东大学学报(工学版), 2025:1-11.

攻读学士学位期间发表的论文和取得的科研成果

致 谢

岁月如梭，大学时光在不经意间已走到终点。聚散有时，回首往昔，点点滴滴犹在眼前。随着毕业离校的脚步日益临近，毕业论文也即将圆满收官。从课题的初步探索到最终的顺利完成，这一路离不开众多师长、亲友的帮助与支持，在此，我满怀感激之情，向他们致以最诚挚的谢意！

首先，我要衷心感谢我的指导老师吕继光老师。在整个毕业设计过程中，吕老师展现出的认真负责的工作态度、严谨的治学作风和深厚的学术造诣，都让我深受启发、获益良多。从论文选题的反复斟酌，到实验方案的精心设计，再到研究过程的稳步推进，吕老师一次次耐心的督促、细致的指导与关键的点拨，都为我指明方向，助力论文研究顺利开展。在论文撰写阶段，吕老师多次审阅文稿，敏锐地指出其中存在的问题，提出宝贵的修改意见。正是因为吕老师的悉心指导，我才能攻克重重难关，完成这篇毕业论文。

其次，我要向大学期间所有授课老师表达深深的谢意。在课堂上，老师们始终秉持着诲人不倦的精神，将专业知识倾囊相授。他们的谆谆教导，不仅让我积累了丰富的专业知识，更培养了扎实的专业技能，为我顺利完成毕业论文筑牢了坚实根基。

此外，我还要特别感谢我的父母。他们为我营造了温暖舒适的成长环境，在人生的每个阶段，都给予我无尽的关爱与坚定的支持。这份支持是我面对困难时的底气，激励我勇敢迎接生活中的每一次挑战。未来，我定会以更加饱满的热情投入学习与工作，用实际行动回报父母的养育之恩。

最后，我要向论文中引用文献的作者致以崇高的敬意，感谢他们的学术成果为我的研究提供了重要参考。同时，也衷心感谢在百忙之中抽出时间审阅本论文的各位专家，感谢你们的宝贵意见与悉心指导。